

Qattn-QDM算法&实验文档

混合量子-经典扩散模型（Qattn-QDM）算法架构文档


1. 文档概述

术语	定义
LD-Diffusion	针对有限数据场景设计的扩散模型，主要应用了数据增强、U-net-attention、连续噪声下的时间嵌入和仿射进行扩散模型的设计，并在100-shot数据集上进行了模型性能测试，为量子扩展的经典主体
Quantum Transformer	量子化 Transformer 编码器，替代经典 Transformer 实现特征提取
VAE	变分自编码器，通过多层线性层和激活函数构成编码器和解码器，将数据在表空间和隐空间进行映射，本文中使用预训练的stability-vae作为隐空间的映射
幅度编码	
角度编码	
量子线路	
隐空间扩散模型	
Qcnn	使用量子线路构造的卷积模块，用于替代经典卷积
Q-SA（Quantum-self-attention）	量子自注意力机制，使用量子线路替代经典注意力中学习注意力的QKV矩阵的部分
Affine	仿射嵌入，使用线性层进行条件信息的特征提取，得到用于对数据特征做偏置和像素放缩的参数，对扩散模型去噪过程中的数据特征进行调制，从而嵌入条件信息


2. 现有技术痛点&算法核心目标

- 当前扩散模型对于有限数据的适配能力较差，容易出现过拟合等问题。其关键在于对去噪网络的改造。而当前主流去噪网络中，不论是基于U-net架构学习图像特征还是基于transformer架构学习序列化数据特征的网络，其容易过拟合的一个关键因素是其海量的参数，难以适配训练数据受限的场景。如果只是压缩模型的规模或是使用简单的模型架构，又容易出现特征提取能力不足的问题。
- 而量子机器学习算法利用量子计算的并行性、量子纠缠特性，能够取得更低的参数量和更好的特征提取能力。因此将经典去噪网络中的部分模块使用量子模块进行替代，能够设计低参数量的扩散模型去噪网络，加快模型的收敛，同时利用量子线路本身的表达能力避免有限数据下扩散模型的过拟合；
- 鉴于当前扩散模型的设计中有大量难以映射到量子机器学习体系下的模块（例如组归一化、连续噪声调度），算法需要采用经典-量子混合模式，使用量子模块替代经典扩散模型去噪过程中参数量大，容易过拟合的模块(卷积、注意力机制等)，最终应当达到的目标是在保持当前已有的有限数据场景下的扩散模型框架的生成精度，同时降低模型的参数量以及计算复杂度。

3. 算法架构总览



(a) Qattn-QDM扩散模型架构图



(b) Qu-UnetBlock

图中展示了Qattn-QDM扩散模型的整体架构图，其基础是一个隐空间扩散模型，通过预训练的VAE进行隐空间映射，将图像特征映射到维度更低的隐空间。图(a)中，模型通过经典的前向加噪过程得到t时刻的数据，并通过去噪网络Qu-Unet预测原始隐空间特征，最后在隐空间中计算模型损失并进行反向传播，更新去噪模型的参数。其中，Qu-Unet是去噪使用的量子U-net，其整体架构与经典U-net相似，通过在模型特征提取的每一个尺度应用Qu-UnetBlock进行特征提取，随后通过上采样/下采样操作在不同特征尺度下进行转换，提取多尺度的图像特征。Qu-UnetBlock架构如图(b)所示，在上采样/下采样得到当前的特征输入之后，首先进行经典的组归一化来归一化特征，随后通过量子QCNN(Quantum Convolutional Neural Network)和量子注意力机制Q-SA(Quantum Self Attention)、量子窗口注意力机制(Quantum LMCW Self Attention)，替代经典卷积和多头注意力，在量子线路上进行特征的提取。在量子卷积计算的中间，通过经典的时间嵌入和仿射调制将时间信息编码为特征向量，随后通过数据重上传的方式映射为量子线路上的参数旋转门，完成时间特征的注入。最后在注意力特征计算完成之后，进行不同注意力机制的残差连接，最后将特征张量进行上采样/下采样进行特征尺度的变换，送入下一层UnetBlock中进行特征提取或是结果的输出。

(1、这张图和上周四讲得有做任何修改吗？ 2、Up/down什么意思 3、x什么意思 4、经典卷积之后是要量子编码吗 如果是 是要表达出来的 5、所有做的测量 编码等操作要表达出出来 6、依然未解决反复编码 测量 的问题)

图像部分的算法整体分为 **5大核心模块**（经典图像数据预处理、经典预训练VAE编码、经典前向加噪、经典-量子混合后向去噪Unet（Qu-Unet）、经典预训练vae解码），并将图像数据输入到算法流程中，经过扩散模型算法的训练和生成，得到生成之后的特征图，用于后续的数据增强。这5大核心算法模块的详细介绍如下：

1.经典数据预处理（明确说清楚预处理要处理什么，什么叫不同图像大小选择自适应模型大小 你在选定一个数据集时 图像尺寸应该是确定的吧 你这不叫预处理 预处理是指你在确定数据集 要对数据做的准备工作）

对于图像数据。输入图像之后，首先对于输入的图像数据 $X \in \mathbb{R}^{B \times C_{in} \times H_{in} \times W_{in}}$ 进行随机翻转 / 裁剪 / 缩放 + 归一化的数据增强策略，得到数据增强之后的数据 $X_{Augment} \in \mathbb{R}^{B \times C_{in} \times H_{in} \times W_{in}}$ ，随后完成数据增强，并输入到Qattn-QDM扩散模型中。

2.经典预训练VAE编码（要说明的是VAE要怎么做 无需举例，要说清楚进入VAE的输入是什么形态，输出是什么形态）

加载预训练VAE(stability-vae)来进行隐空间的放缩。输入图像 $X_{Augment} \in \mathbb{R}^{B \times C_{in} \times H_{in} \times W_{in}}$ ，VAE的编码器 ϵ 会将图像编码到隐空间中得到特征图在隐空间当中的表示 $z_0 \in \mathbb{R}^{B \times C \times H \times W}$ ，随后输入隐空间扩散模型中进行前向加噪和后向Qu-Unet去噪，分别得到当前采样噪声水平下图像的加噪表示 $z_t \in \mathbb{R}^{B \times C \times H \times W}$ 和去噪网络恢复的原始图像 $\hat{z}_0 \in \mathbb{R}^{B \times C \times H \times W}$

设输入图像 X 大小为 $3 \times 128 \times 128$ ，经过预训练VAE的编码器之后会得到 $3 \times 16 \times 16$ 的隐空间输出 z ，作为后续输入隐空间扩散模型训练的张量。

$$X \in \mathbb{R}^{1 \times 3 \times 128 \times 128} \rightarrow z \in \mathbb{R}^{1 \times 3 \times 16 \times 16}$$

3.经典前向加噪层（描述清楚前向加噪 同时我建议仍然选用之前讨论的量子加噪方式）

从标准高斯分布 $N(0,1)$ 中随机生成与输入图像尺寸一致的噪声张量 $\epsilon \in \mathbb{R}^{B \times C \times H \times W}$ ，并随机采样当前的噪声水平 $\sigma_t \in [10^{-2}, 10^4]$ ；随后使用该噪声对扩散模型进行加噪，核心加噪逻辑是得到当前时间刻采样的 σ_t 下的加噪结果 z_t

$$z_t = z_0 + \sigma_t \cdot \epsilon$$

加噪过程无中间步骤，直接从干净样本 z_0 生成任意噪声强度的含噪样本 z_t ，效率远高于DDPM的离散递推加噪。

4.经典-量子混合后向去噪（基于Qu-Unet）

Qu-Unet架构概览

反向去噪模块的训练过程采用“经典-量子混合U-net”，输入t时刻的加噪结果 z_t ，预测输出 $\hat{z}_0$ ，随后计算原始图像 z_0 和预测图像 $\hat{z}_0$ 的loss并对去噪网络进行参数更新。核心是将经典LD-Diffusion的“噪声预测器”中以Unet的主架构中容易过拟合、参数量大的部分(卷积、注意力计算)替换成量子模块，在减少参数量的同时保持乃至增强当前的生成效果。具体来说，Qu-Unet基于VQC算法，使用量子线路进行卷积、注意力模块的特征提取，并采用经典的损失计算-参数优化-梯度下降进行参数更新，上采样/下采样以及线性层、激活函数等可训练参数较少的、量子机器学习算法效果难以实现的部分仍然交由经典算法实现（需要强调的是为什么这么做 而非是为了干而干 只是替换），去噪模型整体数据流为： z_t （含噪数据） $\rightarrow$ Qu-Unet噪声预测器预测 $\hat{\epsilon} \rightarrow$ 经典去噪计算 $\hat{z}_0 \rightarrow$ 损失计算、梯度下降和参数更新。

1. Qu-Unet噪声预测：

- 设含噪数据为 z_t ，经过Qu-Unet预测器（记为 P ），预测出 $\hat{z}_0$ ，即 $\hat{z}_0 = P(z_t)$ 。

2. 损失计算：

- 设预测数据为 z_0 ，损失函数记为 L ，则损失 $L = L(\hat{z}_0, z_0)$ 。使用均方误差损失进行训练

（你就说你用什么损失函数即可）
$$L = \frac{1}{N} \sum_{i=1}^N (Z_{ti} - Z_{0i})^2$$
（其中 N 为数据维度即图像的

总像素 $N = B \times C \times H \times W$ ， Z_{ti} 和 Z_{0i} 分别是 Z_t 和 Z_0 的第 i 个像素元素指的是什么）。

3. 梯度下降和参数更新：

- 设模型参数为 θ ，学习率为 η 。根据损失函数 L 计算其关于参数 θ 的梯度 $\nabla_{\theta} L$ ，然后按照梯度下降公式更新参数 $\theta_{new} = \theta - \eta \nabla_{\theta} L$ 。

Q-Unet的输入为特征图 x ，随后通过Q-UnetBlock进行特征提取,并通过上采样，下采样，将图像特征转变到不同的分辨率下(16×16 ， 8×8 ， 4×4)，从而让模型能够关注不同维度表示下的特征，各个分辨率之间使用上采样/下采样和跳跃连接来进行维度转化。

Q-UnetBlock模块介绍

在UnetBlock中的模块主要有时间嵌入模块、卷积模块、组归一化GN模块、仿射调制模块、注意力模块。在经典UnetBlock中，计算流程为下采样/上采样->输入特征图 x ->GroupNorm组归一化->量子

qcnv卷积->经典时间嵌入+仿射->仿射数据重上传->量子qcnv卷积+多头注意力->当前分辨率输出->下采样/上采样，之后交由下一个UnetBlock进行计算。Unet完成下采样和上采样之后，输出预测噪声，并进行后续的去噪计算。在经典U-netBlock的基础上做了以下修改：

- 在我们的量子QU-UnetBlock中，保留经典时间嵌入+仿射调制，仅在仿射调制完成后，使用量子旋转门参数的形式将参数注入到量子卷积的线路中。
- 使用量子qcnv替代经典卷积，使用量子线路替代经典卷积核进行分组特征提取
- 并使用量子注意力机制替代经典注意力机制来进行注意力的计算。这种替换方式能够显著减少核心算法部分的参数量和计算复杂度，同时利用量子线路的特征提取能力和表达能力，来避免模型在小样本下学习缓慢、容易过拟合的问题。要表达出来你的工作 体现出哪些是已有工作 哪些是你自己的工作 需要你逐模块介绍每个模块的功能 无需体现具体的函数设计 在后续各个模块具体介绍的时候再体现

Qu-Unet详细流程

在隐空间的不同的特征图尺度(eg: 16×16 , 8×8 , 4×4)下，Q-UnetBlock将架构图经典卷积+组归一化GN+时间嵌入+仿射调制+量子卷积+MLP线性层+量子注意力组合成完整的特征提取流程。首先定义各模块函数：需要按照流程进行表达 设下采样函数为 $DownSample(\cdot)$ ，上采样函数为 $UpSample(\cdot)$ 。经典卷积函数为 $Conv_{classical}(\cdot)$ ，组归一化函数为 $GN(\cdot)$ ，时间嵌入函数为 $TimeEmbedding(\cdot)$ ，仿射调制函数为 $Affine(\cdot)$ ，量子卷积函数为 $QConv(\cdot)$ ，量子注意力函数为 $QAttention(\cdot)$ ，量子线路测量函数为 $Measure(\cdot)$ 。

1. Q-UnetBlock模块组成按照步骤描述

- Q-UnetBlock是本文的核心创新部分，主要聚焦于对量子卷积算法的设计和对量子注意力机制算法的设计，分别为 $QConv(\cdot)$ 和 $QAttention(\cdot)$
- 假设输入为 $z_{in} \in \mathbb{R}^{B \times C \times H \times W}$ ，先进行下采样，得到 $z_{down} \in \mathbb{R}^{B \times C \times \frac{H}{2} \times \frac{W}{2}}$ ：
 $z_{down} = DownSample(z_{in})$ ；如果是上采样路径，则得到 $z_{up} \in \mathbb{R}^{B \times 2C \times 2H \times 2W}$
 $z_{up} = Concat(UpSample(z_{in}), z_{output})$ ，其中 z_{output} 是对应的下采样层的输出，两者进行 skip connection，表示为。随后经过量子卷积和组归一化得到第一组卷积的中间量子态：
 $|\psi_{conv-gn}\rangle = GN(Qconv(z_{down/up}))$ 。
- 结合时间嵌入和仿射调制： $z_{affine} = Affine(z_{down/up}, TimeEmbedding(\sigma_t))$ ，其中 σ_t 是时间步。做完一遍经典的 再来一遍量子的？？？
- 时间嵌入在量子卷积中间部分通过数据重上传机制，以参数化量子门的形式注入到量子卷积的线路中，再经过量子卷积、和量子注意力，得到当前Q-UnetBlock的输出。
- 随后进行特征图分块，使用幅度编码进行分组量子卷积。测量得到卷积结果之后，再使用一次组归一化，最后通过量子注意力机制进行特征提取，过程为
 $z_{output} = QAttention(GN(Qconv(|\psi_{conv-gn}\rangle)))$ ：此 z_{output} 即为当前分辨率下UnetBlock的输出。
- 如果是上采样模块，在Q-UnetBlock计算结束之后，额外增加一层经典卷积层，这里主要目的是将特征图通道维度进行压缩，过程为 $z'_{output} = conv(z_{output})$ ， $z'_{output} \in \mathbb{R}^{B \times C \times 2H \times 2W}$

2. Qu-Unet计算流程：写法不对 你只是介绍了干了啥 没有技术

- 与经典U-net一致，QU-Unet首先做一次经典卷积进行通道维度的放缩，从输入的 $z_t \in \mathbb{R}^{B \times C \times H \times W}$ 卷积得到输出 $z_{conv} \in \mathbb{R}^{B \times C_{Unet} \times H \times W}$ eg: $1 \times 3 \times 16 \times 16$ 增加通道到 $1 \times 128 \times 16 \times 16$ ，从最高分辨率开始，经过一系列下采样的Q-UnetBlock，下采样过程为 $z_{H \times W} \xrightarrow{DownSample+Q-UnetBlock} z_{\frac{H}{2} \times \frac{W}{2}} \xrightarrow{DownSample+Q-UnetBlock} z_{\frac{H}{4} \times \frac{W}{4}}$ 。接下来为了描述方便，统一设H=W=16, eg: $z_{16 \times 16} \xrightarrow{DownSample+Q-UnetBlock} z_{8 \times 8} \xrightarrow{DownSample+Q-UnetBlock} z_{4 \times 4}$ ，在每个分辨率下按上述UnetBlock流程计算，即 $z_{H \times W}^{out} = Q - UnetBlock(z_{H \times W}^{in})$ 。
- 然后从最低分辨率 4×4 开始,再进行一次Q-UnetBlock的计算 $z_{4 \times 4}^{out} = Q - UnetBlock(z_{4 \times 4}^{in})$ 上采样并结合跳跃连接（此处跳跃连接将下采样路径对应分辨率的特征与上采样结果进行连接操作），上采样过程为 $z_{4 \times 4} \xrightarrow{UpSample+Q-UnetBlock} z_{8 \times 8} \xrightarrow{UpSample+Q-UnetBlock} z_{16 \times 16}$ ，同样在每个分辨率下按UnetBlock流程计算。
- 最终再通过经典卷积进行通道放缩，输出预测图像，假设最终输出层函数为 $OutputLayer(\cdot)$ ，则 $\hat{z}_0 = OutputLayer(z_{16 \times 16})$ 。

5.经典预训练VAE解码

在图像生成过程中，根据当前去噪网络预测得到的隐空间张量 $\hat{z}_0$ 进行解码，设解码器为 $\mathbb{D}$ ，则解码过程为：

$$\hat{x} = D(\hat{z}_0)$$

4. 各模块详细说明

本模型架构的主要创新来自于构建了可用于各种扩散模型计算架构的量子-经典混合Unet Qu-Unet，主要通过将UnetBlock中卷积+注意力的主要特征提取算法改造成量子模块，来减少主干特征提取部分的参数量、计算量，使用量子线路的特征提取和表达能力，增加生成图像的多样性，并且避免过拟合，验证整个模型的效果。同样的问题 不是为了改造而改造 而是要指出这么干的原因

上一节已经介绍了整体Unet预测噪声的流程和Q-UnetBlock整体流程，接下来详细介绍Q-UnetBlock如何进行量子化改造的。你的模块划分在哪里 为什么上来就是时间嵌入与放射

(1) 上采样/下采样

将输入特征图 $z \in \mathbb{R}^{B \times C \times H \times W}$ 进行上采样/下采样，得到下采样 $z_{down} \in \mathbb{R}^{B \times C \times \frac{H}{2} \times \frac{W}{2}}$ ，上采样则得到 $z_{up} \in \mathbb{R}^{B \times 2C \times 2H \times 2W}$ 。eg: $z_{down} \in \mathbb{R}^{B \times 128 \times 8 \times 8} = DownSample(z \in \mathbb{R}^{B \times 128 \times 16 \times 16})$ ，上采样部分则另外进行skip connection跳跃连接。

(2) GN

使用组归一化(group norm, GN)，对下采样/上采样的图像x进行初步的归一化，保持训练稳定。

(3) 经典时间嵌入+仿射调制进行多特征的时间信息注入

步骤1：时间嵌入预处理

时间预处理：

输入的噪声标准差 σ_t 首先被转换为对数形式， $c_{\text{noise}} = \frac{1}{4} \ln(\sigma_t)$

频率投影：

将标量 $w = c_{\text{noise}}$ 扩展为向量 $v \in \mathbb{R}^{d/2}$ 的过程(d 为嵌入维度)。通过**Fourier Embedding**，从高斯分布中采样随机频率。首先进行频率初始化,从正态分布中采样频率向量 $f \in \mathbb{R}^{d/2} : f \sim \mathcal{N}(0, s^2)$ ，其中 $s = 16$ 。随后投影计算： $v = 2\pi \cdot f \cdot w$

正弦激活

将投影后的向量通过正弦和余弦函数变换，拼接得到维度为 d 的嵌入向量。

$\text{Emb}_{\text{raw}} = [\cos(v), \sin(v)]$ ，即： $\text{Emb}_{\text{raw}} = [\cos(v_0), \dots, \cos(v_{\frac{d}{2}-1}), \sin(v_0), \dots, \sin(v_{\frac{d}{2}-1})]$

线性投影：

将 Emb_{raw} 通过全连接层映射为维度为 $2d$ 的嵌入向量，并且拆分为 $\text{Emb}_{\text{scale}}$ 和 $\text{Emb}_{\text{shift}}$ 两个维度为 d 的向量。这样就得到了用于仿射调制的 $\text{Emb}_{\text{scale}} \in \mathbb{R}^{B \times C}$ 和 $\text{Emb}_{\text{shift}} \in \mathbb{R}^{B \times C}$

步骤2：特征图预处理

将输入特征图 $x \in \mathbb{R}^{B \times C \times H \times W}$ 进行群归一化（GroupNorm）后，利用 scale 和 shift 进行逐通道的线性变换。


- 公式：

$$z_{\text{affine}} = (1 + \text{scale}) \cdot \text{GroupNorm}(x) + \text{shift}$$

这里使用 $1 + \text{scale}$ 是为了让初始状态（当 scale 接近 0 时）接近恒等映射，有助于训练稳定性。

之后在经典unet中 z_{affine} 直接和特征图 z 逐个元素相加，完成时间嵌入和仿射调制。我们的架构中通过线性层linear进行维度压缩之后，编码为旋转门的参数进行数据重上传。

(2)QMLP+QAffine(量子时间嵌入+量子仿射)(旧方法已不使用，留档)



步骤1: 前置准备——时间嵌入输入预处理（经典端）这个和时间嵌入和仿射的关系是什么

经典特征张量预处理:

- ~~重塑张量的空间维度~~说专业术语: 已知输入经典特征图哪里来的原始经典特征张量 $x \in \mathbb{R}^{B \times C \times H \times W}$, 则 $x_{flat} = \text{reshape}(x, (B, C, H \times W))$
- ~~L2归一化~~: 对于 x_{flat} 中每个通道的 $H \times W$ 维向量 v 哪里来的~~x~~, 执行 $\|v\|_2 = 1$ 归一化, 即
$$v_{norm} = \frac{v}{\|v\|_2}$$
- ~~特征维度放缩~~: 设量子比特数 n , 若 v_{norm} 的最后一维 $d = H \times W$ 小于 $2^n = 64$, 则通过补零操作得到 v_{pad} , 使得 $v_{pad} \in \mathbb{R}^{B \times C \times 2^n}$; 若 $d > 2^n$, 则通过池化操作 (设池化函数为 $Pool(\cdot)$) 进行降维, 即 $v_{pool} = Pool(v_{norm}, 2^n)$, 最终输出适配量子编码的特征张量, $v_{quant} \in \mathbb{R}^{2^n}$ 整体特征图表示为 $x_{quant} \in \mathbb{R}^{B \times C \times 2^n}$ ~~没有维度适配的说法 你要根据上述处理接下来要干啥 用多少量子比特数 没人给你规定 是你自己来决定的 同时你也没有提到编码 和量子比特数也看不到有什么关系~~

输入的噪声标准差 σ_t 首先被转换为对数形式, $c_{noise} = \frac{1}{4} \ln(\sigma_t)$

频率投影:

将标量 $x = c_{noise}$ 扩展为向量 $v \in \mathbb{R}^{d/2}$ 的过程 (d 为嵌入维度)。通过 **Fourier Embedding**, 从高斯分布中采样随机频率。首先进行频率初始化, 从正态分布中采样频率向量 $f \in \mathbb{R}^{d/2} \div f \sim \mathcal{N}(0, s^2)$, 其中 $s = 16$ 。随后投影计算: $v = 2\pi \cdot f \cdot x$

正弦激活

将投影后的向量通过正弦和余弦函数变换, 拼接得到维度为 d 的嵌入向量。

$\text{Emb}_{\text{raw}} = [\cos(v), \sin(v)]$, 即:

$$v_{quant} = \text{Emb}_{\text{raw}} = [\cos(v_0), \dots, \cos(v_{\frac{d}{2}-1}), \sin(v_0), \dots, \sin(v_{\frac{d}{2}-1})]$$

步骤2: 量子时间嵌入——将(t)融入特征张量(量子+经典)方法论要和代码实现区分 不要把代码实现的预研拿到这里来阐述

特征编码: 设幅度编码函数为 $\text{AmpEncoding}(\cdot)$, 将 v_{quant} 的64维单通道向量振幅编码为 6 个“图像 qubit”的量子态 $|\psi_{img}\rangle = \text{AmpEncoding}(X_{quant})$ 你就说清楚你这里的特征是怎么来的 然后怎么进行编码 由多少维度编码到多少个的量子比特数上 如何编

时间编码: 步数 t 的预处理应该和编码放在一起说

$\theta_t = 2\pi \cdot \mu_t$, 通过 幅度编码作用于 1 个“时间 qubit”, 生成时间量子态 $|\psi_t\rangle$


量子纠缠融合:

- 以时间 qubit 为控制比特，对所有图像 qubit 施加 $CNOT$ 门，生成融合量子态 $|\psi_{joint}\rangle$ ，则 $|\psi_{joint}\rangle = CNOT(|\psi_t\rangle, |\psi_{img}\rangle)$

以上我看来都是编码的过程

(3) Hardware Efficient Ansatz

量子线路提取线路特征：通过 hardware efficient ansatz(HEA)进行特征提取，层数 $l=3$ 。过程表示为 $|\psi_{t-emb}\rangle = VQC_{time}(|\psi_{joint}\rangle)$ ，hardware efficient ansatz 如图所示：



具体的计算过程中，设量子系统包含 N 个 qubit，其索引依次为 $q_0, q_1, \dots, q_{N-1}$ 。HEA 的深度为 L ，意味着“旋转 + 纠缠”的操作会堆叠 L 层。每一层存在可训练参数 $\theta = \theta_{l,i,\alpha}$ ，其中 $L \in (1, L)$ ， $i \in (0, N-1)$ ， $\alpha \in (R_X, R_Y, R_Z)$ 用于标识旋转门的类型。

2. HEA 的整体么正算子公式

HEA 的整体么正算子 $U_{HEA}\theta$ 由以下公式描述：

$$U_{HEA}(\theta) = \left(\prod_{l=1}^L [U_{ent}(l) \cdot U_{rot}(l)(\theta^{(l)})] \right) \cdot U_{rot}(L+1)(\theta^{(L+1)})$$

单比特旋转层

对所有 qubit 并行施加由硬件原生门组合而成的单比特旋转门，其公式为

$$U_{rot}(l)(\theta^{(l)}) = \bigotimes_{i=0}^{N-1} R_{\alpha_1}(\theta_{l,i,1}) R_{\alpha_2}(\theta_{l,i,2}) R_{\alpha_3}(\theta_{l,i,3})$$

$R_{\alpha_1} = R_Y$ ， $R_{\alpha_2} = R_Z$ ， $R_{\alpha_3} = R_Y$ （即 $R_Y - R_Z - R_Y$ 组合），公式简化为

$$U_{rot}(l)(\theta^{(l)}) = \bigotimes_{i=0}^{N-1} R_Y(\theta_{l,i,1}) R_Z(\theta_{l,i,2}) R_Y(\theta_{l,i,3})$$

符号解释：

$\bigotimes$ ：表示张量积，意味着这些门并行作用于不同的 qubit。

$R_Y(\theta) = \begin{pmatrix} \cos(\theta/2) & \sin(\theta/2) \\ -\sin(\theta/2) & \cos(\theta/2) \end{pmatrix}$ ，这是绕 Y 轴的旋转门。

$R_Z(\theta) = \begin{pmatrix} e^{-i\theta/2} & 0 \\ 0 & e^{i\theta/2} \end{pmatrix}$ ，这是绕 Z 轴的旋转门。

$\theta_{l,i,1/2/3}$ ：分别代表第 l 层、第 i 个 qubit 的第 1、2、3 个可训练参数。

两比特纠缠层

基于 CNOT 门的纠缠特征提取：

使用环形纠缠方案，具体连通的 qubit 对为 $(q_0, q_1), (q_1, q_2), \dots, (q_{N-2}, q_{N-1}), (q_{N-1}, q_0)$ ；使用 CNOT 门，其公式为

$$U_{ent}(l) = \prod_{(i, (i+1)\%N)} CNOT_{i,i+1}$$

其中 C 是硬件连通的 qubit 对集合。 $CNOT_{i,i+1}$ 表示控制 qubit 为 i 、目标 qubit 为 $i+1$ 的 CNOT 门，其作用是仅当控制 qubit 处于 $|1\rangle$ 状态时，翻转目标 qubit。

测量解码（经典化）：编码完就要测量了 从逻辑上讲 应该不是在这里出现吧

- 对所有图像 qubit 执行 $Pauli - Z$ 期望测量，设测量函数为 $MeasureZ(\cdot)$ ，得到经典特征向量 $v = MeasureZ(|\psi_{joint}\rangle)$ 都要测量？？还是测量哪些位
- 时间 qubit 的测量概率 $p_0 = |\langle 0|\psi_t\rangle|^2$ ，用 p_0 加权特征向量 v ，即 $v_{weighted} = p_0 \cdot v$
- 还原维度：通过线性层将 $v_{weighted}$ 从 2^n 恢复为 $[B, C, H, W]$ ，得到融入时间信息的经典特征张量 $X_{time} = Linear(v_{weighted}, (B, C, H, W))$ 如何恢复

步骤3：量子 Affine 逻辑呢 跟在哪一步后面

- 双分支 VQC 执行**：对应经典 affine 层，生成 scale 参数了 shift 参数，分别对时间嵌入后的特征图进行幅度放缩和像素平移看不懂了
- Scale 分支**：谈不上一个分支 就是一个编码呀
- 设 $VQC_{scale}(\cdot)$ 为 Scale 分支的 VQC 操作，以 $v_{weight} \in \mathbb{R}^{2^n}$ 哪里来的为输入，进行幅度编码到 n 比特上多大规模，随后通过 hardware efficient ansatz 生成 scale 量子态 $|\psi_{scale}\rangle = VQC_{scale}(v_{weight})$
- Shift 分支**：
- 设 $VQC_{shift}(\cdot)$ 为 Shift 分支的 VQC 量子线路是个什么操作，和 scale 分支操作相同，对 $v_{weight} \in \mathbb{R}^{2^n}$ 进行幅度编码，生成 shift 量子态 $|\psi_{shift}\rangle = VQC_{shift}(v_{weight})$ 这个态咋来的
- 量子态测量（参数提取）**：编码完就要测量了？ 从逻辑上讲 应该不是在这里出现吧
- 对 $|\psi_{scale}\rangle$ 执行 $Pauli - Z$ 期望测量，得到期望值数组 $E_{scale} = MeasureZ(|\psi_{scale}\rangle)$ ；对 $|\psi_{shift}\rangle$ 执行 $Pauli - Z$ 期望测量，得到期望值数组 $E_{shift} = MeasureZ(|\psi_{shift}\rangle)$
- 经典映射**：我只是编码一下 没有任何训练学习 编码完就测量 我转一下的意义何在呢

$$s = \frac{2 \cdot \frac{1}{N} \sum_{i=1}^N E_{scale}^i + 1}{2}, \quad b = \frac{1}{N} \sum_{i=1}^N E_{shift}^i$$

- **维度扩展**：对于每个通道 $[C]$ 运行了上述的图像张量的编码和测量之后，得到 C 个参数 $S \in s_1, s_2, \dots, s_C$ 和 $B \in b_1, b_2, \dots, b_C$ 哪里涉及了维度扩展 用在哪里 没逻辑 太乱
- 设维度扩展函数为 $ExpandDim(\cdot)$ ，将 S 从 $[C]$ 扩展为 $[B, C]$ ，即 $S_{expanded} = ExpandDim(S, (B, C))$ ；将 B 从 $[C]$ 扩展为 $[B, C]$ ，即 $B_{expanded} = ExpandDim(B, (B, C))$ ，输出经典调制参数 $S_{expanded} \in \mathbb{R}^{B \times C}$ 、 $B_{expanded} \in \mathbb{R}^{B \times C}$

步骤4：经典调制 —— 仿射变换执行（经典端）这一步是干嘛

- **维度扩展**：谁来广播将 $S_{expanded}$ 和 $B_{expanded}$ 从 $[B, C]$ 调整维度为 $[B, C, 1, 1]$
- **仿射调制计算**：

$X_{mod} = X_{time} \cdot S_{expanded} + B_{expanded}$ ，输出调制后的特征张量 $X_{mod} \in \mathbb{R}^{B \times C \times H \times W}$

步骤5：后处理 —— 激活 + 残差连接（经典端）应分的步骤呀

- **激活函数**：
- 设激活函数为 $Activation(\cdot)$ ，若为 $SiLU$ 函数， $X_{activated} = SiLU(X_{mod})$ ；若为 $ReLU$ 函数， $X_{activated} = ReLU(X_{mod})$
- **残差连接**：

$X_{final} = X_{activated} + X$ ，输出 $X_{final} \in \mathbb{R}^{B \times C \times H \times W}$

步骤6：输出到 UnetBlock 下一环

- 将 X_{final} 输入 UnetBlock 的量子卷积(QConv)/ 下采样 / 上采样环节

~~Affine（仿射调制）层的作用及对比时间嵌入的优势（参考）~~ 这些优势又不是你设计的优势 是已有方法的优势

~~Affine 层（严格来说是「条件仿射调制层」）是Elucated Diffusion Model（EDM）论文重构扩散模型设计空间的核心模块之一。对比于直接时间嵌入的局限性。~~

~~一、Affine 层（条件仿射调制）的核心作用（论文核心论证）~~

~~EDM 中的 Affine 层并非普通的线性仿射变换，而是基于归一化的噪声条件仿射调制，论文将其定位为“连续噪声条件注入的最优范式”，核心作用可总结为 3 点：~~

~~作用 1：高效注入连续噪声水平 σ_t 的条件信息（核心）~~ 你没有连续噪声 你都是离散噪声

~~论文指出，扩散模型的核心需求是让模型感知“当前样本的噪声强度”，而 EDM 用连续噪声水平 σ_t 替代了传统离散时间步 t 。Affine 层的核心作用是：将 σ_t 的高维嵌入向量转化为「逐通道缩放因子 γ 和偏移因子 β ，并通过对比归一化后的特征图进行逐通道缩放 + 偏移，让模型的每一层特征变换都能精准适配当前的噪声强度 σ_t 。~~

- 具体效果：高噪声 (σ_t 大) 时， γ 增大以强化特征缩放，提升去噪能力；低噪声 (σ_t 小) 时， γ 减小、 β 微调，聚焦细节还原，实现全噪声区间的平滑适配。

作用 2：解耦归一化的“特征压制”问题，保留表达能力

EDM 的残差块中普遍使用 GroupNorm（组归一化）来稳定训练，但论文指出：归一化层通过强制激活值均值为 0、方差为 1，压制了网络的表达能力。

- Affine 层的解决方式：在归一化后通过 γ （缩放）和 β （偏移）为每个通道提供“个性化矫正”——既保留归一化带来的训练稳定性，又恢复甚至增强通道的关键特征表达，避免归一化导致的信息丢失。
- 论文实验支撑：消融实验显示，移除 Affine 调制后，模型 FID 分数上升 15% 以上，尤其在低噪声区间的细节还原能力显著下降。

作用 3：实现“全局条件+局部特征”的高效结合

σ_t 的嵌入向量是全局条件信息（整个批次共享噪声强度的全局规律），而特征图是局部空间特征（每个像素/通道的局部信息）。论文指出，Affine 层通过“全局 $\sigma_t \rightarrow$ 逐通道 $\gamma/\beta \rightarrow$ 局部特征调制”的链路，实现了全局条件与局部特征的解耦且高效的结合——既不需要为每个空间位置学习独立的条件参数，又能让局部特征适配全局噪声条件。

二、Affine 层相比“直接时间嵌入”的核心优势 说这么没有用 我要看的你的创新

传统扩散模型（如 DDPM/ADM）采用“直接时间嵌入”：将离散时间步 t 映射为高维向量后，直接与特征图相加 / 拼接（additive time embeddings）。EDM 论文通过设计空间消融实验（Table 4），明确了 Affine 调制的 4 大核心优势：

对比维度	直接时间嵌入（传统方式）	Affine 调制（EDM）
条件适配性	仅适配离散时间步 t ，时间步间存在“断点”，无法平滑适配连续噪声强度	适配连续噪声水平 σ_t ， γ/β 随 σ_t 连续变化，无离散断点
条件注入效率	直接相加 / 拼接易导致“条件信息被特征淹没”，需增大嵌入向量维度才能生效，参数冗余	调制归一化后的特征（量纲统一）， γ/β 的微小变化即可显著影响特征表达，注入效率高
训练稳定性	加法注入易导致特征分布漂移，尤其在小批次 / 小样本场景下梯度震荡	结合归一化使用，特征分布更稳定，梯度波动降低 40% 以上（论文实验数据）
参数与计算效率	需为时间嵌入学习独立的大维度权重矩阵（如 DDPM 的 1024 维嵌入），参数多、计算冗余	仅需少量全连接层生成 γ/β （维度与通道数一致），参数减少 60% 以上


三、论文EDM (Elucidating the Design Space of Diffusion-Based Generative Models) 对“直接时间嵌入”的结论

论文明确指出：将时间嵌入直接加到特征图上对扩散模型是次优选择，尤其是转向连续噪声水平时（我们的核心设计）。加法方式无法匹配扩散过程的连续性，且导致条件注入低效。

四、总结

1. **Affine 层核心作用**：高效注入连续噪声水平 σ_t 的条件信息、解耦归一化的特征压制效应、实现全局条件与局部特征的高效结合；
2. **相比直接时间嵌入的优势**：适配连续噪声（无断点）、注入效率更高、训练更稳定、参数 / 计算更高效；
3. **论文核心立场**：直接时间嵌入适配离散时间步，无法满足 EDM “连续噪声建模” 的核心设计，而 Affine 调制是连续噪声框架下条件注入的最优范式，也是 EDM 实现 “高效 + 稳定” 的关键之一。

(2) Qconv量子卷积 (v2)



步骤1：前置准备 —— 经典调制后特征的分块预处理（衔接前序输出）

1. 卷积窗口分块：

- 设输入特征张量 $z_{GN} \in \mathbb{R}^{B \times C \times H \times W}$ ，卷积窗口大小为 $k \times k$ （默认 $k = 3$ ），分组大小 $G = 8$
- 窗口数量 $N = \frac{(H + 2padding - k)}{stride} \times \frac{(W + 2padding - k)}{stride}$ 。
-通过分块操作得到局部窗口特征块 $z_{patch} \in \mathbb{R}^{B \times C \times N \times k^2}$ ，分块操作可表示为：

- 对于 $h = 0, 1, \dots, \frac{(H + 2padding - k)}{stride}$ 和 $w = 0, 1, \dots, \frac{(W + 2padding - k)}{stride}$,
 $z_{patch}[b, c, n, :] = z_{final}[b, c, h \times stride : h \times stride + k, w \times stride : w \times stride + k].reshape(k^2)$
 , 其中 $b \in \{0, 1, \dots, B - 1\}$, $c \in \{0, 1, \dots, C - 1\}$,
 $n = h \times \frac{(W + 2padding - k)}{stride} + 1 + w$
- 随后在通道维度进行分组, 以 $G \times k \times k$ 的窗口大小为一组, 如此 $z_{patch} \in \mathbb{R}^{B \times \frac{C \times N}{G} \times G \times k^2}$

2. 归一化与维度适配:

- 对于 z_{patch} 中每个窗口的 k^2 维向量 z , 进行 L2 归一化: $z_{norm} = \frac{z}{\|z\|_2}$, 其中

$$\|z\|_2 = \sqrt{\sum_{i=1}^{k^2} z_i^2}.$$
- 设量子比特数 n , 若 $k^2 \neq 2^n$, 当 $k^2 < 2^n$ 时, 通过补零操作将 z_{norm} 扩展为 2^n 维向量 z_{pad} ; 当 $k^2 > 2^n$ 时, 通过线性层将 z_{norm} 降维为 2^n 维向量 z_{linear} 。最终得到适配量子编码的窗口特征块 $z_{qpatch} \in \mathbb{R}^{B \times C \times N \times 2^n}$ 。

步骤2: 量子卷积层 (VQC) 的构建与执行 (核心量子环节)

- 使用线性层将 $G \times k \times k$ 的特征映射到 $2^n = 64$ 维度上, 即每个 $z_{linear} = Linear(z_{qpatch})$
- 量子振幅编码:**
 对于 $G \times k \times k$ 特征块 $z_{linear} \in \mathbb{R}^{2^n}$, 将其映射为 n 比特量子态 $|\psi_{patch}\rangle = \sum_{i=0}^{2^n-1} z_{linear,i} |i\rangle$
 , 由于前置 L2 归一化, 满足 $\langle \psi_{patch} | \psi_{patch} \rangle = 1$ 。
- 量子旋转层:**
 对每个 qubit (i) 施加 “RY - RZ - RY” 可训练旋转门, 旋转角度 $\theta_{3i}, \theta_{3i+1}, \theta_{3i+2} \in [0, 2\pi)$ 为 QConv 的可训练参数。用 U_{rot} 表示旋转操作,

$$U_{rot}|\psi_{patch}\rangle = \prod_{i=0}^{n-1} qml.RY(\theta_{3i}, wires = i) \circ qml.RZ(\theta_{3i+1}, wires = i) \circ qml.RY(\theta_{3i+2}, wires = i)|\psi_{patch}\rangle$$
 。
- 量子纠缠层:**
 采用 “环形 CNOT 门”, 对 qubit 按 $0 \rightarrow 1 \rightarrow 2 \rightarrow \dots \rightarrow n - 1 \rightarrow 0$ 的顺序施加 CNOT 门。设 U_{ent} 表示纠缠操作, 对于 (n) 个 qubit,

$$U_{ent}|\psi_{rot}\rangle = \prod_{i=0}^{n-2} qml.CNOT(wires = [i, i + 1]) \circ qml.CNOT(wires = [n - 1, 0])|\psi_{rot}\rangle$$
 , 其中 $|\psi_{rot}\rangle$ 是经过旋转层后的量子态。
- 数据重上传:**

将经典数据 z_{qpatch} 使用另一个线性层，映射到维度为N的张量上：

$$z_{reupload} = \text{Linear}_{G \times k \times k \rightarrow N}(z_{qpatch}), z_{reupload} \in \mathbb{R}^N$$

随后取 $\theta_{reupload} = [\theta_0, \theta_1, \dots, \theta_N]$, $N = 6$, 作为旋转门角度参数直接注入量子线路的旋转门 $[RY_{\theta_0}, RY_{\theta_1}, \dots, RY_{\theta_N}]$ 当中

- 时间调制与嵌入：

- 在上一步的时间嵌入和affine仿射中，我们得到了嵌入张量 $z_{affine} \in \mathbb{R}^{B \times C \times H \times W}$ ，这里我们按照分组的通道，同样进行分组，得到 $z_{affine} \in \mathbb{R}^{B \times \frac{C}{8} \times 8 \times H \times W}$ ，随后经过线性层Linear进行维度压缩，得到 $z_{emb} \in \mathbb{R}^{B \times \frac{C}{8} \times N}$ ，随后逐个进行数据重上传，设量子卷积层ansatz有L层，在量子ansatz执行到 $\frac{L}{2}$ 层时，进行数据重上传，将 z_{emb} 按照通道对应的维度取

$\theta_{emb} = [\theta_0, \theta_1, \dots, \theta_N]$, $N = 6$ ，然后编码为量子线路上的旋转角度 $[RY_{\theta_0}, RY_{\theta_1}, \dots, RY_{\theta_N}]$ ，作为旋转门参数直接注入对应分组的量子线路中。

步骤3：量子态测量与经典特征还原


- 幅度编码下的计算基测量：
- 对每个 qubit 执行 计算基测量，得到 2^n 维经典向量E
- 窗口拼接：
- 将 N 个窗口的还原特征按空间位置拼接，恢复为 $[B, C, H, W]$ 的特征张量 z_{qconv} 。设拼接函数为 $Stitch(\cdot)$ ， $z_{qconv} = Stitch(\{z_{reduced}^n\}_{n=0}^{N-1})$ ，其中 $z_{reduced}^n$ 是第 n 个窗口还原后的特征。最终输出量子卷积后的经典特征张量 $z_{qconv} \in \mathbb{R}^{B \times C \times H \times W}$ 。

步骤4：后处理 —— 特征激活 + 残差连接


- 激活函数：为 $SiLU$ 函数， $z_{activated} = SiLU(z_{qconv}^{fused})$
- 残差连接：

$z_q = z_{activated} + z_{final}$ ，输出最终量子卷积特征 z_q ，输入 UnetBlock 的量子注意力环节。


QLMCW-SA(w=2)



Q-SA



(2) Qconv量子卷积 (v1)



步骤1: 前置准备 —— 经典调制后特征的分块预处理（衔接前序输出）

1. 卷积窗口分块:

- 设输入特征张量 $X_{final} \in \mathbb{R}^{B \times C \times H \times W}$ ，卷积窗口大小为 $k \times k$ （默认 $k = 3$ ），步幅 $stride = 1$ ，填充 $padding = 1$ 。

- 窗口数量 $N = \frac{(H + 2padding - k)}{stride} \times \frac{(W + 2padding - k)}{stride}$ 。
-通过分块操作得到局部窗口特征块 $X_{patch} \in \mathbb{R}^{B \times C \times N \times k^2}$ ，分块操作可表示为：
- 对于 $h = 0, 1, \dots, \frac{(H + 2padding - k)}{stride}$ 和 $w = 0, 1, \dots, \frac{(W + 2padding - k)}{stride}$ ，
 $X_{patch}[b, c, n, :] = X_{final}[b, c, h \times stride : h \times stride + k, w \times stride : w \times stride + k].reshape(k^2)$
，其中 $b \in \{0, 1, \dots, B - 1\}$ ， $c \in \{0, 1, \dots, C - 1\}$ ，
 $n = h \times \frac{(W + 2padding - k)}{stride} + 1 + w$

2. 归一化与维度适配：

- 对于 X_{patch} 中每个窗口的 k^2 维向量 x ，进行 L2 归一化： $x_{norm} = \frac{x}{\|x\|_2}$ ，其中
$$\|x\|_2 = \sqrt{\sum_{i=1}^{k^2} x_i^2}。$$
- 设量子比特数 n ，若 $k^2 \neq 2^n$ ，当 $k^2 < 2^n$ 时，通过补零操作将 x_{norm} 扩展为 2^n 维向量 x_{pad} ；当 $k^2 > 2^n$ 时，通过池化操作（设池化函数为 $Pool(\cdot)$ ）将 x_{norm} 降维为 2^n 维向量 x_{pool} 。最终得到适配量子编码的窗口特征块 $X_{qpatch} \in \mathbb{R}^{B \times C \times N \times 2^n}$ 。

步骤2：量子卷积层（VQC）的构建与执行（核心量子环节）

- 量子振幅编码：**
- 对于单窗口特征块 $x_{qpatch} \in \mathbb{R}^{2^n}$ （单通道、单窗口），将其映射为 n 比特量子态
$$|\psi_{patch}\rangle = \sum_{i=0}^{2^n-1} x_{qpatch,i} |i\rangle$$
，由于前置 L2 归一化，满足 $\langle \psi_{patch} | \psi_{patch} \rangle = 1$ 。
- 量子旋转层：**
- 对每个 qubit (i) 施加 “RY - RZ - RY” 可训练旋转门，旋转角度 $\theta_{3i}, \theta_{3i+1}, \theta_{3i+2} \in [0, 2\pi)$ 为 QConv 的可训练参数。用 U_{rot} 表示旋转操作，
$$U_{rot}|\psi_{patch}\rangle = \prod_{i=0}^{n-1} qml.RY(\theta_{3i}, wires = i) \circ qml.RZ(\theta_{3i+1}, wires = i) \circ qml.RY(\theta_{3i+2}, wires = i)|\psi_{patch}\rangle$$
。
- 量子纠缠层：**
- 采用 “环形 CNOT 门”，对 qubit 按 $0 \rightarrow 1 \rightarrow 2 \rightarrow \dots \rightarrow n - 1 \rightarrow 0$ 的顺序施加 CNOT 门。设 U_{ent} 表示纠缠操作，对于 (n) 个 qubit，
$$U_{ent}|\psi_{rot}\rangle = \prod_{i=0}^{n-2} qml.CNOT(wires = [i, i + 1]) \circ qml.CNOT(wires = [n - 1, 0])|\psi_{rot}\rangle$$
，其中 $|\psi_{rot}\rangle$ 是经过旋转层后的量子态。

步骤3：量子态测量与经典特征还原

- **Pauli - Z 期望测量：**
- 对每个 qubit 执行 Pauli - Z 算符的期望值测量，对于 $|\psi_{conv}\rangle$ ，得到 n 维经典向量 $E = [\langle\psi_{conv}|Z_0|\psi_{conv}\rangle, \dots, \langle\psi_{conv}|Z_{n-1}|\psi_{conv}\rangle]$ ，其中 $E_i \in [-1, 1]$ 。幅度编码则使用计算基测量，得到 2^n 维经典向量
- **维度还原：**
- 将 n 维测量结果映射回经典卷积窗口维度， $x_{reduced} = Linear(E)$ 。
- **窗口拼接：**
- 将 N 个窗口的还原特征按空间位置拼接，恢复为 $[B, C, H, W]$ 的特征张量 X_{qconv} 。设拼接函数为 $Stitch(\cdot)$ ， $X_{qconv} = Stitch(\{x_{reduced}^n\}_{n=0}^{N-1})$ ，其中 $x_{reduced}^n$ 是第 n 个窗口还原后的特征。最终输出量子卷积后的经典特征张量 $X_{qconv} \in \mathbb{R}^{B \times C \times H \times W}$ 。

步骤4：后处理 —— 通道融合 + 残差连接（对齐经典卷积）

- **通道融合（可选）：**
- 若 QConv 设计为多通道输出（如输入 (C) 通道 $\rightarrow$ 输出 $(2C)$ 通道），设 $Conv_{1 \times 1}(\cdot)$ 为经典 1×1 卷积操作， $X_{qconv}^{fused} = Conv_{1 \times 1}(X_{qconv})$ 。
- **激活函数：**
- 设激活函数为 $Activation(\cdot)$ ，若为 $SiLU$ 函数， $X_{activated} = SiLU(X_{qconv}^{fused})$ ；若为 $ReLU$ 函数， $X_{activated} = ReLU(X_{qconv}^{fused})$ 。
- **残差连接：**

$X_{qconv} = X_{activated} + X_{final}$ ，输出最终量子卷积特征 X_{qconv} ，输入 UnetBlock 的量子注意力环节。

(3) 量子注意力机制 (Quantum Attention / QSANN)

基于核方法的量子注意力，利用量子态的高维希尔伯特空间特性计算特征相似度。

- **输入：**特征图 z ，重塑为 Token 序列 $z \in \mathbb{R}^{B \times C \times N \times N_{token}}$ 。具体是通过取特征图中 $C \times p \times p$ 的大小，作为一个 token，并通过线性层映射投射到量子比特编码维度 N_{token} 上， N 同上节 qcnn 窗口数量计算方式。
- **编码方式：幅度编码 (Amplitude Encoding)。**
 - 将 N_{token} 维向量 L2 归一化，幅度编码为量子比特的波函数 $|\psi_v\rangle = \sum_{i=0}^{63} v_i |i\rangle$ 。
- **三路量子分支 (Q/K/V Branches):**
 - **公共编码：**所有分支共享基础编码线路 U_{enc} 。
 - **Q/K 分支：**

- 施加独立变分线路 U_Q, U_K 。
- 测量: Pauli-Z 期望值 $\rightarrow$ 投影至低维空间 $\rightarrow$ q, k 向量。
- **V 分支:**
 - 施加独立变分线路 U_V 。
 - 测量: 计算基底概率 $P(|i\rangle) = |\langle i|\psi_V\rangle|^2$ 。由于 $i \in [0, 63]$ ，直接得到 64 维概率向量作为 v 向量。
- **注意力计算 (RBF Kernel):**
 - 不同于经典的 Dot-Product，这里使用径向基函数（RBF）核：
$$\alpha_{i,j} = \exp\left(-\frac{\|q_i - k_j\|^2}{\tau}\right)$$
 - 其中 τ 为可训练的温度参数。
- **输出:** $Attention(X) = \text{softmax}(\alpha) \cdot v$ 。
- Q-SA输出：计算所有 $i, j \in (0, N)$ 之间的注意力参数 $\alpha_{i,j}$
- Q-LMCW-SA输出：给定窗口 $w = u$ ，则计算窗口数量的大小为u范围内的注意力参数 $\alpha_{i,j}$ 。

维度	评估指标
经典维度	FID 分数、生成样本视觉质量、下游分类准确率/召回率、模型参数量、模型计算量FLOPS
量子维度	量子模块计算参数量比较+FLOPS比较

5. 训练流程示例：

训练全程使用连续噪声水平 σ_t ，无离散时间步，具体流程分 6 步，：

一、前置准备：输入图像预处理

1. **格式标准化**：将图像像素值归一化到 $[-1,1]$ 区间（或 $[0,1]$ ，需与去噪器输出一致），转换为张量格式 $x_0 \in [B, C, H, W]$ （B批次、C=3通道、H/W分辨率）；
2. **数据增强（可选）**：启用自适应数据增强（ADA），如随机水平翻转、平移，避免小样本过拟合，增强模型泛化能力。

连续噪声水平 σ_t 采样（核心控制变量）

用连续噪声水平 σ_t 替代离散时间步，这是训练的核心起点：

1. **采样区间**：从预设连续区间 $[\sigma_{min}, \sigma_{max}]$ （典型范围 $1e-4 \sim 1e3$ ）中，为每个批次样本独立采样 σ_t （批次内每个样本的 σ_t 可不同，提升泛化性）；

2. **采样策略**：采用对数均匀采样，即对 $\log \sigma_t$ 均匀采样后指数化，确保在低噪声区间（ σ_t 小）和高噪声区间（ σ_t 大）均有足够采样密度，避免模型偏向某类噪声强度；
3. **输出格式**：采样后的 σ_t 为张量[B,1]，与批次样本维度对齐，后续将作为预条件传入去噪器。

二、前向加噪（一步生成含噪样本，无离散递推）

前向加噪无需分步迭代，直接基于采样的 σ_t 一步生成含噪样本，贴合连续 SDE 的数学本质：

1. **噪声生成**：从标准高斯分布 $N(0, I)$ 中生成与输入图像尺寸一致的噪声张量 $\epsilon \in [B, C, H, W]$ ；
2. **加噪公式**：含噪样本 z 的生成逻辑为：

$$z = z_0 + \sigma_t \cdot \epsilon$$

1. （注：公式中 σ_t 通过广播机制适配[B,C,H,W]维度，即每个样本的所有像素点均添加对应 σ_t 强度的噪声）；
2. **核心特点**：加噪过程无中间步骤，直接从干净样本 z_0 生成任意噪声强度的含噪样本 z ，效率远高于 DDPM 的离散递推加噪。

三、模型前向传播（预条件去噪器 + Affine 调制）

将含噪样本 x 和噪声水平 σ_t 传入 EDM 的核心——预条件去噪器 $D_\theta(z, \sigma_t)$ ，完成特征提取与去噪预测：

1. 噪声水平 σ_t 的预条件注入（Affine 调制核心流程）

- 第一步： σ_t 嵌入。对 σ_t 做对数归一化（ $\log \sigma_t$ 映射到[0,1]），通过对图像进行编码，并进行特征提取，生成嵌入向量 v_{time} 并线性映射到嵌入图 $x_{time} \in [B, C, H, W]$ ；
- 第二步：生成仿射参数。将 v_{time} 通过两个量子线路，拆分为缩放因子 $scale \in [B, C]$ 和偏移因子 $shift \in [B, C]$ （C为去噪器输入通道数）；
- 第三步：Affine 调制。对嵌入特征先对特征图做 GroupNorm 归一化，再通过scale（逐通道缩放）和shift（逐通道偏移）调制特征，公式：

$$X_{mod} = scale[B, C, 1, 1] \cdot X_{time} + \beta[B, C, 1, 1]$$

- 实现 σ_t 与特征的深度融合，让模型适配当前噪声强度。

2. 去噪器特征处理（Qu-UNet 架构）

- 模型输出：去噪器直接输出去噪后的干净样本预测值 $\hat{z}_0 = D_\theta(z_t, \sigma_t)$ ，维度与输入图像 z_0 完全一致（[B,C,H,W]），无需通过噪声反推（区别于 DDPM）。

四、损失计算（单噪声水平独立 L2 损失，无累积）

针对当前采样的 σ_t 优化去噪精度：

1. **损失公式**：采用 L2 去噪损失，直接比较模型输出的去噪样本 $\hat{z}_0$ 与真实干净样本 z_0 的差异：

$$L = E_{z_0, \epsilon, \sigma_t} \|\hat{z}_0 - z_0\|_2^2$$

1. （期望针对批次样本、噪声 ϵ 、噪声水平 σ_t 的采样分布）；
2. **损失特性**：每个噪声水平 σ_t 的损失独立计算，梯度更平滑，避免 DDPM 多时间步损失的累积误差；低噪声区间损失聚焦细节还原，高噪声区间损失聚焦全局结构恢复，模型学习目标更明确；
3. **可选正则化**：可添加轻微权重衰减（如 $1e-5$ ）或 Dropout（ $p=0.1$ ，仅残差块中启用），进一步抑制过拟合。

五、反向传播与参数更新（优化去噪器权重）

1. **梯度计算**：基于 L2 损失，通过自动微分（PyTorch/TensorFlow 原生支持）计算损失对去噪器所有可训练参数（权重、偏置、仿射参数生成网络权重等）的梯度；
2. **梯度优化**：
 - 梯度裁剪：对全局梯度范数进行裁剪，避免高噪声区间梯度震荡；
 - 优化器选择：采用 Adam 或 AdamW 优化器，初始学习率典型为 $1e-4$ ，随训练轮次线性衰减至 $1e-5$ ；
3. **参数更新**：按优化器的更新规则（如 Adam 的动量项、权重衰减）调整去噪器参数，完成一轮训练迭代；
4. **工程优化**：启用混合精度训练（FP16），降低显存占用，提升训练吞吐量；支持大批次训练（ $B=32\sim64$ ），加速收敛。

六、训练监控与模型保存（迭代至收敛）

1. **迭代流程**：重复步骤 1~5，直至训练轮次达到预设值（或损失收敛），典型训练轮次对应“样本迭代量”（如 20000kings，即训练数据总量 $\times$ 迭代次数 = 20000k 样本）；
2. **模型保存**：保存损失最低或 FID 最高的去噪器权重（含去噪器网络、 σ_t 嵌入网络的所有参数），用于后续推理采样。

为什么和DDPM扩散模型的训练流程不一样？

这里是基于连续噪声模型建模的扩散模型，时间被定义为连续可微的变量，因此噪声本身也被定义为连续的变量。因此扩散模型在进行时间嵌入时选择的是单个噪声水平 σ_t ，并计算该噪声水平下的加噪结果，去噪之后将预测样本和原始样本进行loss计算。

通常认知的DDPM扩散模型在加噪方面定义为离散马尔可夫链，每步加噪服从高斯分布，递推公式为：

$$x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{1 - \alpha_t} \epsilon_t$$

当 $T \rightarrow \infty$ 时，每步加噪强度 $\alpha_t \rightarrow 1$

最终， x_t 的边际分布可表示为：

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$$

（其中 $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ ， $\epsilon \sim \mathcal{N}(0, I)$ ），即“干净样本 + 噪声强度加权的高斯噪声”。

第一步：离散→连续的极限转换（核心数学推导）

当 $T \rightarrow \infty$ 时，将离散时间步 t 归一化到连续时间区间 $t \in [0, 1]$ ，定义“连续噪声强度” $\sigma(t)$ ，满足：

$$1 - \bar{\alpha}_t \approx \sigma(t)^2$$

（物理意义：DDPM 中“累积噪声占比”对应 EDM 中“噪声强度 $\sigma(t)$ 的平方”）。

此时，DDPM 的离散加噪递推公式通过伊藤引理转化为连续随机微分方程（SDE）：

$$dx = f(x, t)dt + g(t)dw$$

其中：

dw 是标准布朗运动（连续噪声的数学表达）。

- 扩散系数 $g(t) = \sigma(t) \cdot \sqrt{2 \log(1/\bar{\alpha}_t)} \approx \sigma(t)$ （当 β_t 极小时的近似）。
- 漂移系数 $f(x, t) = -\frac{1}{2}g(t)^2 \cdot \frac{\nabla_x \sigma(t)^2}{2\sigma(t)^2}x$ （由边际分布的梯度推导得出，核心是“引导样本向噪声演化”）。
- DDPM 当 $T \rightarrow \infty$ 时，任意时刻 t 的含噪样本 x_t ，均可直接表示为“干净样本 + 噪声强度 $\sigma(t) \times$ 高斯噪声”，与离散递推无关。
- 简化公式直接跳过连续 SDE 的复杂演化，复用边际分布形式，一步生成含噪样本：
 $x = x_0 + \sigma_t \cdot \epsilon \quad (\epsilon \sim \mathcal{N}(0, I))$

关键对应：

EDM 的 σ_t 即 DDPM “连续化后的噪声强度”， σ_t 的调度函数（如指数调度）对应 DDPM 的 (β_t) 序列（递增且连续）。

推导结论：加噪过程是 DDPM “ $T \rightarrow \infty$ ” 时的边际分布简化版，用“一步加噪”替代“分步递推”。

第二步：离散反向去噪→连续概率流（核心数学推导）

当 $T \rightarrow \infty$ 时，DDPM 的后向离散迭代推导为“概率流 ODE”（确定性去噪过程），表达式为：

$$dx = \left[f(x, t) - \frac{1}{2}g(t)^2 \nabla_x \log p_{\sigma_t}(x) \right] dt$$

公式解读：

$f(x, t)$ 和 $g(t)$ 与前向 SDE 一致（连续扩散的核心参数）。

$\nabla_x \log p_{\sigma_t}(x)$ 是分数函数（指向数据高密度区域的“梯度方向”），本质是“去噪的引导信号”。

- 物理意义：**含噪样本沿“分数函数引导的方向”，连续平滑地还原为干净样本，无随机噪声干扰（区别于 DDPM 的随机后向过程）。

第三步：模型的去噪目标简化（工程化关键）

分数函数的等价表达：

在连续极限下，分数函数可表示为去噪器的函数：

$$\nabla_x \log p_{\sigma_t}(x) = \frac{x_0 - x}{\sigma_t^2}$$

其中 x_0 是干净样本， x 是含噪样本。

- 去噪器设计直接学习 “含噪样本→干净样本” 的映射 $D_{\theta}(x, \sigma_t) = x_0$ ，而非预测噪声，此时分数函数可间接推导为：

$$\nabla_x \log p_{\sigma_t}(x) = \frac{D_{\theta}(x, \sigma_t) - x}{\sigma_t^2}$$

- 模型的去噪过程是 DDPM “ $T \rightarrow \infty$ ” 时的概率流极限，用 “直接去噪器” 替代 “噪声预测器”，既降低误差累积，又提升采样效率。

因此这里在训练的过程中通过采样一个时间步的方式，对这个时间步 σ_t 下去噪得到 $\hat{z}_0$ 和当前加噪样本 z_0 进行loss的计算。

6. ~~量子模块编码测量复杂度推导（基于单线路编解码复杂度 ω ）（v1方法，存档）~~

你想基于“单个量子线路编解码复杂度为 ω ” 的前提，推导QLD-Unet中量子时间嵌入+量子Affine、量子Conv卷积、量子注意力三个核心模块的编码测量总复杂度——核心逻辑是先明确 ω 的定义，再结合各模块的“量子线路执行次数（线路数） $\times$ 批次/通道/窗口等维度参数”，推导总复杂度公式。

一、先统一复杂度定义

首先明确 ω 的构成（保证推导基准一致）：

单个量子线路编解码复杂度 ω = 经典→量子编码复杂度（ E ）+ 量子→经典测量解码复杂度（ M ），即：

$$\omega = E + M$$

E ：经典特征映射为量子态的复杂度（如振幅编码 $\propto 2^n$ ， n 为qubit数）；

M ：量子态还原为经典特征的复杂度（如计算基测量 $\propto 2^n \times \text{shots}$ ，shots为测量次数）。

二、各模块编码测量复杂度推导

1. 量子时间嵌入（QTE）+ 量子Affine（QA）的总复杂度

执行逻辑（贴合仓库）

- 量子时间嵌入（QTE）：对每个批次（ B ）、每个通道（ C ）的特征张量，逐通道执行1次量子线路编解码（1条线路=1个 ω ），线路为4比特量子线路；
- 量子Affine（QA）：以“融入时间的特征”为输入，逐通道执行双分支VQC（scale/shift分支各1条线路，共2条线路=2个 ω ），线路为3比特量子线路。
- 复杂度公式

$$QTE\text{时间嵌入复杂度} = B \times C \times 1 \times \omega \times 2^4 = 16BC\omega$$

$$QA_{\text{Affine}}\text{复杂度} = B \times C \times 2 \times \omega \times 2^3 = 16BC\omega$$

$$\text{总复杂度} = QTE + QA = 32BC\omega$$

- 若批次 $B = 2$ 、通道 $C = 4$ ，则总复杂度 $= 3 \times 2 \times 4 \times \omega = 256\omega$ ；
(QTE用4 qubit、QA用3 qubit，单线路 ω 因qubit数略有差异，归一化后公式仍成立)。
- 2. 量子Conv (QConv) 的编码测量复杂度
- 执行逻辑 (贴合仓库)
- 经典分块：将特征张量 $[B, C, H, W]$ 按 $k \times k$ 卷积窗口分块，得到 N 个窗口 (N 为窗口总数)：
$$N = \left\lfloor \frac{H + 2p - k}{s} + 1 \right\rfloor \times \left\lfloor \frac{W + 2p - k}{s} + 1 \right\rfloor$$
- 其中 $p = \text{padding}$ 、 $k = \text{kernel size}$ 、 $s = \text{stride}$ ；
- 量子编解码：对每个批次、每个通道、每个窗口，逐窗口执行1次量子线路编解码 (1条线路=1个 ω)。
- 复杂度公式

$$\text{QConv总复杂度} = B \times C \times N \times \omega$$

- 参数示例
- 设 $k = 3$ 、 $p = 1$ 、 $s = 1$ 、 $H = W = 8 \rightarrow N = 8 \times 8 = 64$ ；幅度编码需要4个量子比特，若 $B = 2$ 、 $C = 4$ ，则总复杂度 $= 2 \times 4 \times 64 \times \omega \times 2^4 = 8192\omega$ 。
- 3. 量子注意力的编码测量复杂度
- 量子注意力中，每个token通过取特征图中 $p \times p \times C$ 的大小得到。因此无需计算通道维度复杂度。
- 复杂度公式 (分两种场景)

场景	单q-k对复杂度	总复杂度 (单头)	总复杂度 (多头)
(q/k预编码)	ω	$B \times (N_q + N_k + N_v) \times \omega$	$B \times H_{\text{head}} \times (N_q + N_k + N_v) \times \omega$
完整编解码 (含q/k编码)	3ω	$3B \times (N_q + N_k + N_v) \times \omega$	$3B \times H_{\text{head}} \times (N_q + N_k + N_v) \times \omega$

- 仓库参数示例
- 仓库中 $N_q = N_k = 8$ 、 $H_{\text{head}} = 4$ 、 $B = 2$ ，则完整编解码复杂度：
 $3 \times 2 \times 4 \times 24 \times \omega \times 2^8 = 98304\omega$

三、复杂度总结 (核心公式)

模块	编码测量总复杂度	关键参数说明

量子时间嵌入+量子Affine	$3BC\omega$	B =批次, C =通道
量子Conv卷积	$BCN\omega$ (N =卷积窗口数)	$N = (H \times W)$ (仓库默认3×3窗口)
量子注意力 (完整编解码)	$3BH_{\text{head}}N_qN_kN_v\omega$	H_{head} =头数, N_q/N_k =q/k数量

• 总结

1. 复杂度量级对比 (仓库默认参数):
量子时间嵌入+Affine (256ω) < 量子Conv (8192ω) < 量子注意力 (98304ω);
2. 优化方向:
- 量子Conv可通过“窗口权重共享”减少线路数;
 - 量子注意力可通过“q/k批量编码”减少工程代码实际内存分配的线路数来加速训练;
3. 与经典复杂度对比:
经典模块复杂度 $\propto BCHWD$ (D 为特征维度), 而量子模块复杂度仅与“线路数 $\times \omega$ ”相关, ω 远小于经典维度 D , 因此量子模块在有限数据场景下更轻量化。

如果将量子时间嵌入+量子affine作为辅助比特进行嵌入，一种容易想到的做法是：使用三个量子线路，一个计算时间嵌入emb，另外两个计算scale和shift。其中，输入部分整体编码和特征提取线路不变，使用特征图幅度编码+时间张量幅度编码嵌入作为辅助比特；经过多层量子线路之后，首先对emb进行测量，得到2比特的时间嵌入，随后继续计算其它两个量子线路，在此基础上纠缠2比特的时间嵌入，计算2层ansatz之后，同样进行测量，仅保留各自的1比特作为时间调制参数，随后这2+1+1比特需要作为辅助比特，时间比特通过CNOT门作为Qconv中Unfold操作得到的线路中的辅助比特，其余两个比特分别使用C-RY(量子态旋转门乘积)和C-RZ(相位偏移)对主线路中4比特进行纠缠，C-RY、C-RZ门参数可训练。

按照这个方案，我们需要为每个Unfold操作都制备一个时间嵌入的量子线路，仍然设B=2，C=4因此量子时间嵌入+affine部分单独的复杂度即为 $3BC\omega \times 2^4 = 384\omega$ ，这样每个量子conv的线路复杂度为 $BC\omega \times 2^4 + 384\omega = 512\omega$ ，整体复杂度变为原来的4倍，即 32768ω 。因此这个方案的复杂度远远大于原本的测量经典scale,shift之后进行调制的方案。

7.对比实验

图像生成实验

图像部分实验主要分为两个受限数据集下和经典baseline的对比，以及一个受限数据集下和其它量子扩散模型的对比，包括FID，准确率，召回率，模型大小，FLOPS指标

针对 100-shot 数据受限的场景，本报告通过量子模块提升特征捕捉效率，目标为生成与真实样本分布一致、细节丰富、多样性高的增强数据，并在下游对数据集的简单分类任务上评价生成的图像的质量。 100-shot 数据集 该数据集包含了100-shot Obama, 100-shot Grumpy Cat, 100-shot Panda数

据，其分布较为接近，能够较好评估生成的图像的质量。数据集图像大小均为3*128*128，每个数据集中有100张对应的图像。其中，100-shot-grumpy-cat和100-shot-obama用于比较我们的方法与经典baseline的扩散模型(重点在LD-Diffusion)上的效果上的差别，100-shot-panda在更小的图像规模上测试当前模型和带量子线路的扩散模型在图像生成上的效果。

[1] Peebles W, Xie S. Scalable diffusion models with transformers[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 4195-4205.

[2] Wang Z, Jiang Y, Zheng H, et al. Patch diffusion: Faster and more data-efficient training of diffusion models[J]. Advances in neural information processing systems, 2023, 36: 72137-72154.

[3] Zhang Z, Hua Y, Sun G, et al. Training diffusion-based generative models with limited data[C]//Forty-second International Conference on Machine Learning. 2025.

[4] Karras T, Aittala M, Aila T, et al. Elucidating the design space of diffusion-based generative models[J]. Advances in neural information processing systems, 2022, 35: 26565-26577.

[5] Dhariwal P, Nichol A. Diffusion models beat gans on image synthesis[J]. Advances in neural information processing systems, 2021, 34: 8780-8794.

100-shot-grumpy-cat数据集结果

方法	FID	准确率 (%)	召回率 (%)	模型大小 (MB)	FLOPS (MB)	期刊级别	发表时间
经典DDPM (DiT) [1]	347.8	/	/	120		(ICCV) CCF-A	2023
Patch- Diffusion[2]	45.1	85.6	46.0	506		(Neurips) CCF-A	2023
LD- Diffusion[3]	16.5	99	33.0	514		(ICML)CC F-A	2025
EDM+DA[4]	41.49	89.7	30.0	634		(Neurips) CCF-A	2022
ADM (Ablated Diffusion Model) [5]	64.78	78.71	27.0	3014		(Neurips) CCF-A	2021
经典-量子混 合扩散模型 (base)	72.4	78.9	28.0	30			
经典-量子混 合扩散模型	17.8	98	37.0	298			

(U-net)							
---------	--	--	--	--	--	--	--

100-shot-obama结果

100-shot-obama(128*128)					
方法	FID	准确率 (%)	召回率 (%)	模型大小(MB)	FLOPS(MB)
经典DDPM (DiT)					
Patch-Diffusion	43.79	86.9	49.0	506	
LD-Diffusion	16.8	97	31.0	514	
EDM+DA	40.45	90.4	54.0	634	
ADM (Ablated Diffusion Model)	62.46	80.7	31.0	3014	
经典-量子混合扩散模型(base)					
经典-量子混合扩散模型(U-net)	15.2	97.8	36.0	298	

100-shot-panda实验在28*28的图像上对比已有的量子扩散模型的效果。其中

[1] Qconv-Unet是使用量子qconv卷积改造的U-net， DE FALCO F, CESCHINI A, SEBASTIANELLI A, et al. Quantum Hybrid Diffusion Models for Image Synthesis[J/OL]. KI - Künstliche Intelligenz, 2024[2024-10-15].

[2] Qlatent_diffusion_model使用隐空间扩散模型进行特征学习，并使用全量子线路VQC进行去噪学习 Cacioppo A, Colantonio L, Bordoni S, et al. Quantum Diffusion Models[J]. arXiv e-prints, 2023: arXiv: 2311.15444.

[3] all_vqc_diffusion_model使用VQC进行扩散模型去噪 Parigi M, Martina S, Caruso F. Quantum - Noise - Driven Generative Diffusion Models[J]. Advanced Quantum Technologies, 2024: 2300401.

[4] 采用量子线路进行加噪和去噪，并且给模型嵌入了时间信息。Zhang B, Xu P, Chen X, et al. Generative quantum machine learning via denoising diffusion probabilistic models[J]. Physical Review Letters, 2024, 132(10): 100602.

100-shot-Panda(28*28)						
方法	FID	准确率 (%)	召回率 (%)	生成时间 (s)	模型大小 (MB)	FLOPS(MB)
Qconv-Unet[1]	118.79	1.2	0.0	230	16.680	
Qlatent_diffusion_model[2]	173.05	3.8	0.0	421	1.013	
all_vqc_diffusion_model[3]	556.00	0.0	0.0	125	0.003	
Quantum generative diffusion model[4]	438.23	0.0	0.0	134	0.276	
经典-量子混合扩散模型 (U-net)						

下面的实验在100-shot-obama上测试LD-Diffusion和我们的量子扩散模型在不同训练步数上的比较，来显示我们的方法能够达到更快的收敛速度和更小的模型参数量

方法/FID	1000kimg	2000kimg	4000kimg	20000kimg	参数量	FLOPS
LD-Diffusion	67.29	27.03	24.45	16.8	531M	
经典-量子混合扩散模型 (U-net)	64.8	25.32	20.3	15.2	519M	
经典-量子混合扩散模型 (U-	64.1	26.17	20.9	15.8	508M	

net+QtimeEmbed)						
经典-量子混合扩散模型 (U-net+QtimeEmbed+Qconv)	66.8	28.49	23.75		501M	

消融实验主要测试改进的注意力机制在量子扩散模型上的效果与改进的量子卷积qcn在扩散模型上的效果。其基准数据集为100-shot-panda-28*28

100-shot-Panda(28*28)					
方法	FID	准确率 (%)	召回率 (%)	生成时间 (s)	模型大小(MB)
Qcn+improved_Qattn					
Qcn					
improved_Qattn					
Qattn					

IPV6地址生成实验

IPv6 地址由 128 位二进制数构成，通常以 8 段 4 位十六进制数表示（如 2001:db8:85a3:0:0:8a2e:370:7334），其高位（前 64 位）代表网络段（如运营商分配的前缀）、低位（后 64 位）代表主机标识，且低位分布依赖高位特征（同一网络段下的主机标识具有相似分布规律）。本实验围绕“生成高活跃性、低重复性的 IPv6 地址”目标，结合经典 - 量子混合扩散模型的特性，设计数据集、实验流程与评估指标，具体如下：

评价指标：由于 IPv6 地址生成最终需要生成活跃的 IPv6 地址，因此对应的评价指标相较常规的图像数据集生成的评价指标有所不同。

IPv6 地址非别名率、命中率、生成率、重复率

$$\text{非别名率 } r_{n-\text{alias}} = \frac{N_{\text{candidate}} - N_{\text{aliased}}}{N_{\text{candidate}}}$$

$$\text{命中率 } r_{\text{hit}} = \frac{N_{\text{hit}} - N_{\text{aliased}}}{N_{\text{candidate}}}$$

$$\text{生成率 } r_{\text{gen}} = \frac{N_{\text{hit}} - N_{\text{olap}} - N_{\text{aliased}}}{N_{\text{candidate}}}$$

$N_{\text{candidate}}$ 为候选地址集总数； N_{aliased} 候选集中别名地址数量。 N_{hit} 候选集中活跃地址总数。 N_{olap} 候选集与种子集重叠的活跃地址数。计算出的指标中，非别名率标志着模型生成地址的独特性，命中率对应图像扩散模型的 FID，标志模型生成数据是否能拟合真实分布，生成率标志着生成数据的多样性，即能够生成与训练集中数据不同数据的能力。

ipv6地址生成实验

ipv6地址生成实验旨在测试模型对于文本序列化数据的拟合和生成能力。通过50000个全量ipv6地址(不限前缀)作为训练集，随后生成100000个地址，作为生成地址集，随后使用zmapv6进行1次/日，扫描7日，计算得到的命中率，生成率等指标。

对比实验简述：Entropy/IP[42]方法基于信息熵分析将地址分段，并利用贝叶斯网络建模段间统计依赖关系来生成地址；6GCVAE[43]: 采用门控卷积变分自编码器（VAE）的架构，将IPv6地址生成问题转化为文本生成问题。6Forest[44]: 使用最大覆盖作为分裂准则优化空间划分，并集成了增强的隔离森林算法以移除异常种子地址。6GAN[45]: 利用生成对抗网络（GAN）并结合强化学习，以生成多种模式的IPv6地址。AddrMiner[46]: 一个快速、高效的全球活跃IPv6地址检测系统，其生成策略基于强化学习。6HMap [47]: 采用双向层次聚类（BHC）方法，旨在生成更有前景的扫描子空间；6Diffusion 基于扩散模型架构，使用Transformer作为去噪网络，并使用窗口注意力机制进行地址特征的学习

参考论文：

- [1] Zhao X, Xu H, Xing R, et al. 6Diffusion-LM: IPv6 address generation method based on diffusion-LM[C]//2024 IEEE International Conference on High Performance Computing and Communications (HPCC). IEEE, 2024: 1556-1563.
- [2] Ren Y, Gou G, Hou C, et al. IPv6 Prefix Target Generation through Pattern and Distribution Learning using Vision-Transformer and Guided-Diffusion[C]//IEEE INFOCOM 2025-IEEE Conference on Computer Communications. IEEE, 2025: 1-10.
- [3] Liu C, Li R, Yuan F, et al. 6Subpattern: target generation based on Subpattern analysis for Internet-wide IPv6 scanning[J]. IEEE Transactions on Network and Service Management, 2024, 21(4): 3692-3710.

- [4] Zhang W, Song G, He L, et al. 6vision: Image-encoding-based ipv6 target generation in few-seed scenarios[C]//2024 IEEE 32nd International Conference on Network Protocols (ICNP). IEEE, 2024: 1-12.
- [5] Yang W, Wang Q, Yao Y. IPv6 active address detection model based on diffusion model[J]. Computer Networks, 2025, 261: 111047.
- [6] Cui T, Gou G, Xiong G. 6gcvae: Gated convolutional variational autoencoder for ipv6 target generation[C]//Pacific-Asia Conference on Knowledge Discovery and Data Mining. Cham: Springer International Publishing, 2020: 609-622.
- [7] Song G, He L, Zhu F, et al. Addrminer: A fast, efficient, and comprehensive global active ipv6 address detection system[J]. IEEE/ACM Transactions on Networking, 2024, 32(5): 3870-3887.
- [8] Foremski P, Plonka D, Berger A. Entropy/ip: Uncovering structure in ipv6 addresses[C]//Proceedings of the 2016 Internet Measurement Conference. 2016: 167-181.
- [9] Z. Liu, Y. Xiong, X. Liu, W. Xie, and P. Zhu, "6tree: Efficient dynamic discovery of active addresses in the ipv6 address space," Computer Networks, vol. 155, pp. 31–46, 2019.
- [10] G. Song, L. He, Z. Wang, J. Yang, T. Jin, J. Liu, and G. Li, "Towards the construction of global ipv6 hitlist and efficient probing of ipv6 address space," in 2020 IEEE/ACM 28th International Symposium on Quality of Service (IWQoS). IEEE, 2020, pp. 1–10.
- [11] B. Hou, Z. Cai, K. Wu, J. Su, and Y. Xiong, "6hit: A reinforcement learning-based approach to target generation for internet-wide ipv6 scanning," in IEEE INFOCOM 2021-IEEE Conference on Computer Communications. IEEE, 2021, pp. 1–10.
- [12] Zhang L, Fu S. 6MCBLM: Multi-scale CNN and BiLSTM-Attention hybrid model for IPv6 target generation[C]//2024 4th International Conference on Neural Networks, Information and Communication Engineering (NNICE). IEEE, 2024: 499-505.
- [13] T. Cui, G. Xiong, G. Gou, J. Shi, and W. Xia, "6veclm: Language modeling in vector space for ipv6 target generation," in Machine Learning and Knowledge Discovery in Databases: Applied Data Science Track: European Conference, ECML PKDD 2020, Ghent, Belgium, September 14–18, 2020, Proceedings, Part IV. Springer, 2021, pp. 192–207.
- [14] T. Yang, Z. Cai, B. Hou, and T. Zhou, "6forest: an ensemble learningbased approach to target generation for internet-wide ipv6 scanning," in IEEE INFOCOM 2022-IEEE Conference on Computer Communications. IEEE, 2022, pp. 1679–1688.
- [15] T. Cui, G. Gou, G. Xiong, C. Liu, P. Fu, and Z. Li, "6gan: Ipv6 multi-pattern target generation via generative adversarial nets with reinforcement learning," in IEEE INFOCOM 2021-IEEE Conference on Computer Communications. IEEE, 2021, pp. 1–10.
- [16] Jiao L, Zhu Y, Zhang W, et al. 6GAI: Active IPv6 Address Generation via Adversarial Training with Leaked Information[C]//2024 27th International Conference on Computer Supported Cooperative Work in Design (CSCWD). IEEE, 2024: 1079-1085.

[17] B. Hou, Z. Cai, K. Wu, T. Yang, and T. Zhou, “Search in the expanse: Towards active and global ipv6 hitlists,” in IEEE INFOCOM 2023-IEEE Conference on Computer Communications. IEEE, 2023, pp. 1–10.

[18] B. Hou, Z. Cai, K. Wu, T. Yang, and T. Zhou, “6scan: A high-efficiency dynamic internet-wide ipv6 scanner with regional encoding,” IEEE/ACM Transactions on Networking, vol. 31, no. 4, pp. 1870–1885, 2023.

IPV6	Ncandidate	Nnon-alias	rn-alias	Nhit	Ngen	rhit	r gen	参数量 (MB)	计算量?	期刊/会议	发表时间
6Diffusion-LM[1]	/	/	/	/	/	43.53%	35.97%	331.27		(CCF-C) 2024 IEEE International Conference on High Performance Computing and Communications (HPCC)	2024/12/1
	100,000	91,346	91.35%	41,873	34,478	41.87%	34.48%				
6ptg[2] (提一下数据量)	100,000	/	/	/	/	51.80%	24.97%			INFOCOM 2025	2025/5/10
	100,000	89,422	89.42%	35,954	35,813	35.95%	35.81%				
6Subpattern[3]	/	/	/	/	/	33.50%-72.16%	/			(SCI Q1, 二区) IEEE Transactions on Network and Service Management	2024/08/01
	100,000	91,116	91.12%	30,542	29,489	30.54%	29.49%				
6Vision[4]	250,000	/	/	/	/	28.34%	/			(CCF-B) International Conference on Network Protocols (ICNP)	2024/10/12
	100,000	89,291	89.29%	37,642	23,805	37.64%	23.81%				
6prefixDiff[5]	/	/	/	/	/	41.60%	/			(SCI Q1, 三区) Computer Networks	2025/4/1

[illegible]

6Vec LM[13]	173,555	102,177	58.87%	37,838	11,223	21.80%	6.47%				
	100,000	57,123	57.12%	24,712	8,794	24.71%	8.79%				
6Forest[14]	106,904	67,334	62.99%	25,043	24,683	23.43%	23.09%				
	100,000	64,124	64.12%	24,015	23,478	24.02%	23.48%				
6GAN[15]	208,192	151,857	72.94%	37,176	37,083	17.86%	17.81%				
	100,000	68,423	68.42%	15,478	14,213	15.48%	14.21%				
6GAI[16]	/	/	/	/	/	20.49%	14.90%			(CCF-B) International Conference on Computer Supported Cooperative Work in Design (CSCWD)	2024/5/1
	100,000	99,695	99.70%	17,816	16,487	17.82%	16.49%				
6HMap[17]	100,000	75,761	75.76%	41,446	39,060	41.45%	39.06%				
	100,000	74,158	74.16%	40,834	38,721	40.83%	38.72%				
6Scan[18]	100,080	25,535	25.51%	16,956	16,825	16.94%	16.81%				
	100,000	28,791	28.79%	18,197	17,941	18.20%	17.94%				
6Diffusion	95,092	88,528	93.10%	44,435	44,372	46.73%	46.66%	331.27			
量子混合扩散模型(中	100,000	50,147	50.15%	23,619	23,048	23.61%	23.04%				

期方案)											
Q-IPv6	100000	92783	92.78%	44821	43970	44.82%	43.97%	87.22/(86.69C+0.53Q)			

消融实验 加不加量子模块，原始量子注意力vs改造的量子注意力机制

IPv6算法	Ncandidate	Nnon-alias	r n-alias	Nhit	Ngen	r hit	r gen	参数量 (MB)
原始qsann注意力的Q-IPv6								
使用当前改造注意力机制的Q-IPv6								

消融实验 是否使用量子时间嵌入+调制的Q-IPv6

IPv6算法	Ncandidate	Nnon-alias	r n-alias	Nhit	Ngen	r hit	r gen	参数量 (MB)
no-time-embed-Q-IPv6	100000	92783	92.78%	44821	43970	44.82%	43.97%	87.22/(86.69C+0.53Q)
Q-timeEmbedded-Q-IPv6	100000	90487	90.49%	42478	41647	42.48%	41.65%	86.79/(85.86C+0.93Q)

前缀实验 使用/64前缀分类进行地址生成的效果（top-5命中率方法）

IPV6算法	Ncandidate	Nnon-alias	r n-alias	Nhit	Ngen	r hit	r gen	参数量 (MB)
6ptg								
6diffusion-LM								
Addrminer								
6diffusion								
6HMap								
Q-IPv6								

8.预实验

实验设计+实验指标补充一下

"我们提出了一种全量子相干调制架构（Integrated Quantum Modulation），通过将经典Affine参数映射为量子旋转角并在深度线路中多次注入，成功在仅使用 36% 参数量的情况下，实现了优于传统经典U-Net Block的特征调制效果，验证了量子网络在紧凑特征表达上的潜力。"

实验一：为什么放弃使用量子线路进行时间嵌入？

首先从理论上来说，经典时间信息嵌入和仿射调制使用的是多个线性层嵌套，提取经过fourier embedding编码的经典特征。其线性层关注的是向量中各个元素之间的特征提取和元素上的特征提取，而如果使用量子线路进行特征提取，就需要使用幅度编码进行归一化（失去时间嵌入的模长信息）或角度编码（需要使用线性层进行特征降维），然后使用量子线路进行计算。因此理论上量子线路提取这种时间嵌入向量的信息的效果不好。

实际实验中，测试模型在一个固定 Batch 数据上的拟合（记忆）能力。输入 x ：随机生成的张量，形状为 $x \in \mathbb{R}^{(32,64)}$ 。目标：一个构造的复杂非线性函数，值域被缩放到 $[0,1]$ 之间 $target = 0.5 \times (\sin(x) + \cos(2x)) + 0.5$ 。这种任务和扩散模型中对于时间嵌入张量进行拟合，生成调制参数的任务较为相似。

对比的三种模型架构

实验同时训练了三个模型来拟合上述目标：

A. 经典 MLP (Teacher/Reference)

- 结构： $\text{Linear}(64 \rightarrow 128) \rightarrow \text{SiLU} \rightarrow \text{Linear}(128 \rightarrow 64)$ 。
- 特点： 扩散模型中使用的时间嵌入方法，拥有全局连接（Fully Connected）和强非线性激活函数（SiLU）。
- 参数量： 作为基准（Benchmark），其参数量用于衡量量子模型是否在同等参数规模下具有竞争力。

B. 量子 MLP (Hybrid Quantum)

- 结构： QuantumMLP 类。 $\text{Linear}(64 \rightarrow 128) \rightarrow \text{Quantum_circuit} \rightarrow \text{Linear}(128 \rightarrow 64)$
- 配置：
 - n_qubits=2 (2量子比特)
 - n_groups=32 (32个并行的独立量子组)
 - q_depth=4 (4层变分线路)
 - encoding='amplitude' (幅度编码)
 - re_uploading=True (数据重上传，增强非线性)
- 特点： 这是实验的主角。通过量子纠缠和旋转门来拟合目标函数。 n_groups=32 意味着它实际上是 32 个独立的 2-qubit 子线路在工作，这限制了它的全局特征混合能力。

C. 线性基准 (Linear Only / Depth=0)

- 结构： QuantumMLP 类，但 q_depth=0。
- 特点： 去掉了中间的变分量子线路（VQC），只保留了输入投影（proj_in）和输出投影（proj_out）。
- 目的： 作为一个消融实验（Ablation Study）。如果 B 模型的效果不比 C 模型好很多，就说明量子线路（VQC）部分没有起到实质性的非线性变换作用，模型仅仅是在训练两端的线性层。

D. 纯量子线路(Pure Quantum/ Depth=4)

- 结构： 将张量x进行幅度编码后，输入6量子比特线路中，进行4层变分线路的训练
- 特点： 纯量子方案，只用一个6比特量子线路编码64维的张量信息。

结果可以看到，HybridQ和L_Only相比，加上量子线路并没有增加很多特征提取能力。相较于经典网络，简单的量子线路在这个任务的拟合中难以起到作用，纯量子线路来说，loss下降速度很慢，难以训练。因此在时间嵌入模块方面，直接使用简单的线性层进行时间嵌入的拟合即可，无需进行量子化改造。


```
=== Benchmark 1: Time Embedding Capacity ===
```

```
Classic Params: 16576
```

```
Hybrid Quantum Params: 13768
```

```
Pure Quantum Params: 97
```

```
LinearOnly Params: 12744
```

```
Training...
```

```
Step 0: C=0.57438, HybridQ=0.88533, PureQ=0.52869, L_Only=0.88055
```

```
Step 50: C=0.05338, HybridQ=0.00209, PureQ=0.51478, L_Only=0.00344
```

```
Step 100: C=0.00471, HybridQ=0.00058, PureQ=0.50352, L_Only=0.00064
```

```
Step 150: C=0.00018, HybridQ=0.00047, PureQ=0.49233, L_Only=0.00049
```

```
Step 199: C=0.00001, HybridQ=0.00044, PureQ=0.48229, L_Only=0.00045
```

```
Final: C=0.00001, HybridQ=0.00044, PureQ=0.48229, L_Only=0.00045
```

实验二：为什么采用当前的量子qcnn卷积和affine嵌入方案？

1.实验目的

实验旨在测试模型在空间特征提取任务上的能力。简单来说，就是测试模型能否根据一个“调制条件”来改变“图像特征”的处理方式，同时捕捉非线性的空间变换，贴合U-net中特征调制(affine)和特征提取(conv)的过程。

- 输入 (x): 形状为 (4, 128, 16, 16) 的模拟图像特征张量。
- 条件 (style): 形状为 (4, 128) 的affine调制向量。
- 拟合目标 (Target): $target = x \cdot \text{sigmoid}(style) + \sin(x)$
- 目标包含两部分：
 1. 乘性调制: $x \cdot \text{sigmoid}(style)$ ，模拟常见的 AdaGN (Adaptive Group Norm) 归一化机制。
 2. 强非线性项: $\sin(x)$ ，模拟非线性特征变化。测试对于图像的非线性特征的提取能力

对比实验通过对比量子qcnn卷积+affine调制的算法和经典卷积+affine调制的算法，来衡量用qcnn卷积替代经典卷积的可行性。

经典算法和扩散模型中UnetBlock的affine调制+卷积算法一致，首先通过GN对特征图进行组归一化，随后通过MLP+affine嵌入条件向量，并生成调制参数，对特征图进行调制，最后通过经典卷积进行特征提取，并得到特征提取的结果。

而量子qcnn卷积中，经典卷积通过取特征图中 $C \times p \times p$ 的特征，随后进行卷积运算。这种方法需要计算规模类似于 $128 \times 3 \times 3$ 的张量,在量子线路中的实现代价过大，并且使用一个量子线路进行特征提取显然需要更深的线路。因此这里对于张量进行分组的特征提取。

2.测试算法具体架构

2.1 Classic Ref (经典参考架构)

标准的经典 U-Net 残差块，作为性能基准（Baseline）。

* **核心模块:** 卷积, affine, 特征调制

* **参数量:** ~427k

* **算法流程:**

1. **Input:** $x \in \mathbb{R}^{B \times C \times H \times W}$, $\sigma_t \in \mathbb{R}^{B \times D}$ 。

2. **Conv Block 1:** $GN \rightarrow SiLU \rightarrow Conv2d$ 提取特征得到 x_{conv1} 。

3. **Affine Modulation:**

* 通过线性层将 σ_t 映射为 $scale$ 和 $shift$ 。

* 公式: $x_{affine} = \text{Norm}(x_{conv1}) \cdot (1 + scale) + shift$ 。

4. **Conv Block 2:** `SiLU -> Conv2d` 处理调制后的特征。

5. **Output:** x_{out} 。

2.2 Separated Quantum (分离式量子架构)

采用 "量子特征提取 + 经典信号调制" 的混合设计,使用qcnv替代经典卷积,时间调制部分仍然在经典部分进行,因此需要额外的测量在第一个卷积之后进行测量 (Q-C-Q Structure)。

* **核心机制:** 利用量子层进行高维特征映射,利用经典层进行幅度调制。

* **参数量:** ~433k (与经典持平)

* **算法流程:**

1. **QConv0 (量子前端):**

* **分组 (Grouping):** 将 C 通道分为 $\frac{C}{8}$ 组 (如128通道分16组)。

* **量子编码:** 对每组张量 $8 \times 3 \times 3$ 进行线性层映射,并进行振幅编码 (Amplitude Encoding) 映射到希尔伯特空间。

* **酉变换:** 执行参数化量子线路 (PQC), 使用4层HEA进行特征提取。

* **测量:** 得到特征 x_{q0} 。

2. **Classic Modulation:**

* 与经典架构完全相同,生成 $scale$, $shift$ 。

* 公式: $x_{affine} = \text{Norm}(x_{q0}) \cdot (1 + scale) + shift$ 。

3. **QConv1 (量子后端):**

* 再次经过量子卷积层处理 x_{affine} 得到 x_{q1}

4. **Output:** x_{q1}

* **优势:** 完美结合了量子计算的强非线性 (特征空间) 和经典计算的数值缩放能力 (幅度空间)。

2.3 Integrated Quantum (集成式量子架构)

尝试完全在量子线路内部完成特征融合，去除显式的经典乘法调制。

- * **核心机制:** 数据重上传 (Data Re-uploading) 与 参数调制。
- * **参数量:** ~155k (仅为经典的 36%)
- * **算法流程:**
 1. **Deep QCNN:** 使用4层深度的量子线路。
 2. **Affine Injection:**
 - * 将 x_{affine} 向量使用线性层映射，并归一化为向量 $\theta_{affine} = [\theta_0, \theta_1, ..., \theta_N], N = 6$, 然后编码为量子线路上的旋转角度 $[RY_{\theta_0}, RY_{\theta_1}, ..., RY_{\theta_N}]$, 作为旋转门参数直接注入量子线路。
 3. **量子演化:**
 - * $|\psi_{out}\rangle = U(\theta_{trainable}) \cdot U(\theta_{affine}) \cdot U(x_{data}) \cdot |0\rangle$ 。
 4. **Output:** 测量期望值并映射回通道空间。
- * **局限:** 量子酉变换本质上是保范数的 (Norm-preserving) ，难以模拟大幅度的数值缩放 (Amplitude Scaling) ，导致拟合复杂调制任务较难。

3. 实验结果与分析

模型架构	初始 Loss	最终 Loss (200 steps)	参数量	评价
Classic Ref	2.18957	0.02238	427k	基准水平，收敛平稳
Separated (Q-C-Q)	2.19203	0.00075	433k	SOTA，误差比经典低一个数量级
Integrated (Pure Q)	2.29448	0.01417	155k	参数效率极高，性能优于经典但弱于分离式

```
=== Benchmark 6: Quantum U-Net Architectures Comparison ===
Classic Ref Params: 427008
Separated Params: 433944
Integrated Params: 154962

Training...
Step 0: Loss Ref=2.18957, Loss Sep=2.19203, Loss Int=2.29448
Step 20: Loss Ref=1.09431, Loss Sep=0.56364, Loss Int=0.48993
Step 40: Loss Ref=0.84324, Loss Sep=0.19471, Loss Int=0.21800
Step 60: Loss Ref=0.49366, Loss Sep=0.07109, Loss Int=0.12678
Step 80: Loss Ref=0.28692, Loss Sep=0.04175, Loss Int=0.08314
Step 100: Loss Ref=0.16920, Loss Sep=0.01372, Loss Int=0.05800
Step 120: Loss Ref=0.10171, Loss Sep=0.00683, Loss Int=0.04202
Step 140: Loss Ref=0.06635, Loss Sep=0.00315, Loss Int=0.03121
Step 160: Loss Ref=0.04235, Loss Sep=0.01384, Loss Int=0.02360
Step 180: Loss Ref=0.02945, Loss Sep=0.00279, Loss Int=0.01808
Step 199: Loss Ref=0.02238, Loss Sep=0.00075, Loss Int=0.01417
Final Loss: Ref=0.02238, Sep=0.00075, Int=0.01417
```

3.1 核心发现

1. **分离式架构的优越性:** 实验数据表明, `Separated` 架构的最终 Loss (0.00075) 远低于经典架构 (0.02238)。这证明了在保留经典调制层 (处理幅度信息) 的基础上, 引入量子卷积层 (处理相位/特征空间信息) 能显著提升模型的表达能力。

3.2 模块输入输出尺寸 (以 C=128, H=16, W=16 为例)

1. 分组处理 (Grouped Processing):

- * 输入: $[B, 128, 16, 16]$
- * 分组: $[B, 16, 8, 16, 16]$
- * Unfold (3x3): 每个 Patch 大小为 $8 \times 3 \times 3 = 72$ 。

2. 量子映射:

- * Data Projection: $72 \rightarrow 64$ (映射到 6 qubits 幅度编码)。
- * Measurement: 64 维实数概率分布。

3. 重组:

- * $[B, 8, 16, 16, 16] \rightarrow [B, 128, 16, 16]$ 。

为什么不直接增加量子比特数, 不进行分组?

“为什么不用 11 个量子比特进行qcnn的编码？ $2^{11} = 2048$ ，正好够用啊？”

- **模拟成本爆炸**：模拟 11 个量子比特的状态向量需要的内存和计算量是 6 个量子比特的 $2^{11-6} = 32$ 倍。在反向传播时会显著变慢。
- **训练难度（贫瘠高原）**：这是最致命的。随着量子比特数增加，梯度消失问题（Barren Plateaus）会呈指数级恶化。训练一个宽而浅（多组、少比特）的线路比训练一个窄而深（单组、多比特）的线路要容易得多。

为什么不像实验一一样，模型的能力来源于线性层？

实验显示，如果将量子线路的特征提取ansatz全部去掉，其训练效果会很差，展示了线性层对于非线性目标函数较差的拟合能力，以及量子线路良好的非线性拟合能力，适合用于特征图的卷积。

```
=== Benchmark 7: Ablation Study (Quantum vs Linear Replacement) ===
Quantum Params: 433944
Linear Params: 138112

Training...
Step 0: Loss Q=2.18239, Loss Linear=2.04378
Step 20: Loss Q=0.59285, Loss Linear=1.12503
Step 40: Loss Q=0.21138, Loss Linear=1.03473
Step 60: Loss Q=0.07779, Loss Linear=0.95941
Step 80: Loss Q=0.03045, Loss Linear=0.88588
Step 100: Loss Q=0.02797, Loss Linear=0.83107
Step 120: Loss Q=0.00985, Loss Linear=0.79065
Step 140: Loss Q=0.00343, Loss Linear=0.76584
Step 160: Loss Q=0.00170, Loss Linear=0.74810
Step 180: Loss Q=0.00086, Loss Linear=0.73073
Step 199: Loss Q=0.00046, Loss Linear=0.70664
Final Loss: Q=0.00046, Linear=0.70664
```



```
=== Benchmark: Attention Encoding Comparison (Classical Conv + X) ===
Comparing: [Classical], [Quantum Amplitude], [Quantum Angle (Tanh)]
Classical Params: 99008
Quantum Amp Params: 99933
Quantum Ang Params: 100713
```

Training...

```
Step 0: Classical=2.01779, Q-Amp=2.01954, Q-Ang=2.01570
Step 20: Classical=1.43977, Q-Amp=1.47735, Q-Ang=1.46881
Step 40: Classical=0.87532, Q-Amp=0.80961, Q-Ang=0.80148
Step 60: Classical=0.60219, Q-Amp=0.50564, Q-Ang=0.50127
Step 80: Classical=0.43051, Q-Amp=0.32875, Q-Ang=0.32816
Step 100: Classical=0.31603, Q-Amp=0.22480, Q-Ang=0.22748
Step 120: Classical=0.24000, Q-Amp=0.16000, Q-Ang=0.16218
Step 140: Classical=0.17475, Q-Amp=0.11878, Q-Ang=0.12210
Step 160: Classical=0.13355, Q-Amp=0.08974, Q-Ang=0.09896
Step 180: Classical=0.14418, Q-Amp=0.07100, Q-Ang=0.07278
Step 199: Classical=0.08460, Q-Amp=0.05487, Q-Ang=0.06086
```

实验三：能在不测量的情况下把量子卷积和量子注意力的算法连接起来吗？

根据当前的qcn算法，每个量子线路所编码的数据是 $X \in \mathbb{R}^{B \times C \times H \times W}$ 当中 $x_{patch} \in \mathbb{R}^{G \times p \times p}$ 通过线性层映射的数据，那么如果要让qcn算法和q-attn算法全量子化，那么直接将q-attn计算的token也确定为 $x_{patch} \in \mathbb{R}^{G \times p \times p}$ 即可。因此，可以得到All-qu算法的架构为：创造三个用于qkv计算的量子线路，在conv部分共享旋转门参数 θ_{conv} ，进行(L=8)层HEA的计算，得到三个相同的量子态 $|\psi_{conv}\rangle$ ，随后的l=8层的HEA的参数 $\theta_{attn} = ((\theta_q^0, \theta_k^0, \theta_v^0), (\theta_q^1, \theta_k^1, \theta_v^1), \dots, (\theta_q^{\frac{C}{G}}, \theta_k^{\frac{C}{G}}, \theta_v^{\frac{C}{G}}))$ 则独立进行参数的训练，最后分别进行测量，计算q,k向量的点积距离和v向量进行注意力的矩阵运算。这实质上是在原本的注意力计算的token单位 $x_{token} \in \mathbb{R}^{C \times p \times p}$ 又做了一次通道维度的分组。

实验对比算法如下：

- 算法一：经典Unet架构，卷积和注意力均使用经典算法，称为Classical baseline
- 算法二：量子卷积+测量+MLP线性层+Silu激活函数+量子注意力，称为Q-Hybrid-baseline
- 算法三：量子卷积+测量+linear线性层+量子注意力，称为Q-Hybrid-Lite
- 算法四：量子卷积+量子注意力（无中途测量），称为Q-Pure-Fused

实验通过加载100-shot-obama数据集，首先通过随机噪声打乱特征图，输入模型中，通过100个epoch的训练让模型恢复出原始图像，并评估恢复图像 $\hat{x}$ 与原始图像 x 之间的mse-loss，来快速评估其在扩散模型去噪网络中的特征提取和恢复的能力。

SSIM (Structural Similarity Index) - 结构相似性

- 含义：从亮度（Luminance）、对比度（Contrast）和结构（Structure）三个维度衡量图像相似度，比 PSNR 更符合人眼视觉感知。数值范围 [0, 1]，越接近 1 越好。

- 计算方式（benchmark_100shot_obama.py 第 34-68 行）：
 - 高斯加权：使用 11x11 的高斯窗口（window_size=11, sigma=1.5）在图像上滑动，计算局部的均值（ μ ）、方差（ σ^2 ）和协方差（ σ_{12} ）。

◦ 核心公式:

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}$$

◦ 代码中设置了常数 $C_1 = 0.01^2, C_2 = 0.03^2$ 以维持数值稳定性。

◦ 最后对全图的 SSIM Map 求平均值作为最终得分。

算法	Loss	参数量	SSIM
Classical baseline	0.015439	493312	0.8041
Q-Hybrid-baseline	0.009039	188659	0.8940
Q-Hybrid-Lite	0.012036	188387	0.8726
Q-Pure-Fused	0.052567	175075	0.6106

可以看出，效果最好的是Q-Hybrid-baseline，其将时间嵌入+卷积特征提取之后的特征，使用线性层+激活函数进行经典的特征激活，随后编码进量子注意力的线路当中进行注意力的计算，有效地利用了两个量子模块，并使用经典线性层+激活函数，使得梯度反传更加流畅，取得了相较经典网络更好的参数量和loss。然而，我们可以发现，使用纯量子线路却起到了反作用：量子线路的深度过深，从而导致梯度反传和训练极为困难，因此我们可以得到一个初步的结论：在不同的量子模块之间，进行经典的激活函数进行特征重塑，有利于训练过程中梯度的反传，能够有效利用量子模块的特征提取能力，又避免了量子算法的贫瘠高原问题。

- 结论：使用Q-Hybrid-baseline算法，替换经典baseline架构，能够取得最好的效果。

实验四：探索量子线路架构中，Affine仿射调制的位置

在经典的时间嵌入+仿射架构当中，仿射调制放在conv1+GN1和conv2+GN2中间的位置；在量子时间嵌入方案当中，仿射调制默认放在量子线路 $l = \frac{L}{2}$ 处，以经典线性层特征降维+量子线路旋转门参数注入的形式，进行特征调制。

现在尝试量子线路中三种不同的调制位置：

- 算法一：放在卷积线路的头部，分组卷积编码之后立即进行参数门调制（Q-head-affine）
- 算法二：放在卷积线路中部，即量子线路深度 $l = \frac{L}{2}$ 处（Q-middle-affine）
- 算法三：放在卷积线路末尾，即量子线路深度 $l = L$ 处（Q-tail-affine）

以及使用经典调制方案，在特征图以经典表示进行调制：

- 算法四：放在卷积线路之前，即GN之后进行调制（C-head-affine）
- 算法五：放在卷积线路之后，即测量后到注意力计算之前进行调制（C-tail-affine）

实验设置同实验三，恢复100-shot-obama图像，实验整体架构同Q-UnetBlock架构相同，只是省略了输入输出部分的上采样和下采样层，统一在128*16*16的特征维度处进行计算，实验结果如下：

算法	Loss	SSIM
Q-head-affine	0.020485	0.8104
Q-tail-affine	0.018050	0.8204
Q-middle-affine	0.017556	0.8271
C-head-affine	0.014753	0.8524
C-tail-affine	0.013285	0.8556